



**WYDZIAŁ
ELEKTROTECHNIKI
I INFORMATYKI**
POLITECHNIKI RZESZOWSKIEJ

Maciej Pereślucha

Zastosowanie algorytmów sztucznej inteligencji do
rozpoznawania autentyczności podpisu

PRACA INŻYNIERSKA

Opiekun pracy:
dr inż. Paweł Górka

Rzeszów, 2026

Spis treści

Wykaz symboli, oznaczeń i skrótów	5
1. Wprowadzenie	7
2. Metody weryfikacji podpisu – przegląd literatury	9
3. Zbiór danych i jego przygotowanie	11
3.1. Zbiór CEDAR	11
3.2. Analiza eksploracyjna danych	12
3.3. Podział na zbiory niezależne od autora	14
3.4. Budowa par podpisów	15
4. Model sieci syjamskiej	17
4.1. Przygotowanie obrazów	17
4.2. Budowa sieci syjamskiej	20
4.3. Funkcja straty i trening	22
5. Badania eksperymentalne i wyniki	25
6. Podsumowanie i wnioski końcowe	27
Literatura	28

Wykaz symboli, oznaczeń i skrótów

CEDAR	Center of Excellence for Document Analysis and Recognition – ośrodek Uniwersytetu w Buffalo, autor zbioru podpisów
CNN	ang. <i>convolutional neural network</i> – splotowa sieć neuronowa
CSV	ang. <i>comma-separated values</i> – format pliku tekstowego z wartościami rozdzielonymi przecinkami
EER	ang. <i>equal error rate</i> – równy współczynnik błędów
MD5	ang. <i>Message Digest 5</i> – algorytm obliczania skrótu pliku
ReLU	ang. <i>rectified linear unit</i> – funkcja aktywacji zwracająca wartość wejścia dla wartości dodatnich i zero dla ujemnych
RGBA	ang. <i>red, green, blue, alpha</i> – zapis obrazu w trzech kanałach koloru i kanale przezroczystości

1. Wprowadzenie

Podpis odręczny jest jednym z najczęściej używanych sposobów potwierdzania tożsamości, na przykład w bankach, u notariusza czy w urzędach. Sprawdzaniem, czy podpis jest prawdziwy, zajmują się zwykle biegli grafolodzy, jednak taka ocena zajmuje dużo czasu i w pewnym stopniu zależy od doświadczenia osoby, która ją wykonuje. Automatyczna weryfikacja podpisu jest badana od kilkudziesięciu lat, ale nadal pozostaje problemem otwartym. Rozwój uczenia głębokiego sprawił, że sieci neuronowe potrafią same nauczyć się cech, po których można odróżnić podpisy różnych osób, bez ręcznego projektowania tych cech [1].

Najprostszym pomysłem byłoby nauczenie sieci rozpoznawania podpisów każdej osoby osobno, tak jak w zwykłym zadaniu klasyfikacji. Takie podejście ma jednak dwie wady. Po pierwsze, od jednej osoby dostępnych jest zwykle niewiele podpisów — w zbiorze użytym w tej pracy są to 24 podpisy na osobę. Po drugie, dodanie do systemu każdej nowej osoby wymagałoby ponownego trenowania modelu. Rozwiązaniem jest sieć syjamska, która składa się z dwóch jednakowych podsieci i zamiast odpowiadać na pytanie, do kogo należy podpis, porównuje ze sobą dwa podpisy i mierzy, jak bardzo są do siebie podobne [2]. Dzięki temu sieć może być stosowana także do osób, których podpisów nie widziała podczas treningu [3].

W pracy wykorzystano podpisy w postaci zeskanowanych obrazów. Taki wariant nazywa się weryfikacją statyczną (ang. *offline*), w odróżnieniu od weryfikacji dynamicznej (ang. *online*), w której podpis składany jest na tablecie rejestrującym na przykład prędkość ruchu pióra. Na obrazie tych informacji nie ma, widoczny jest tylko kształt podpisu. Najtrudniejsze do wykrycia są fałszerstwa wykwalifikowane, czyli podpisy podrobione przez osobę, która wcześniej ćwiczyła naśladowanie oryginału [4]. Wstępna analiza danych wykonana w ramach pracy pokazała, że proste porównanie obrazów piksel po pikselu myli się w około jednej trzeciej przypadków, dlatego potrzebna jest bardziej zaawansowana metoda.

Celem pracy było opracowanie systemu, który na podstawie zeskanowanego obrazu sprawdza, czy podpis jest autentyczny, oraz ocena jego skuteczności. System oparto na sieci syjamskiej i zaprojektowano tak, aby działał również dla osób, których podpisy nie były używane podczas treningu. Zakres pracy obejmował:

- przegląd literatury dotyczącej weryfikacji podpisu i sieci syjamskich,
- analizę zbioru podpisów CEDAR,

- przygotowanie danych, w tym podział osób na osobne zbiory treningowy, walidacyjny i testowy oraz utworzenie par podpisów,
- implementację sieci syjamskiej w języku Python,
- trening sieci i ocenę jej skuteczności na zbiorze testowym,
- analizę otrzymanych wyników.

2. Metody weryfikacji podpisu – przegląd literatury

3. Zbiór danych i jego przygotowanie

3.1. Zbiór CEDAR


Do trenowania i testowania modelu wykorzystano zbiór podpisów CEDAR, przygotowany w ośrodku Center of Excellence for Document Analysis and Recognition Uniwersytetu w Buffalo. Zbiór zawiera podpisy 55 osób, z których każda złożyła 24 podpisy prawdziwe w wyznaczonym polu o wymiarach 2×2 cale. Falszerstwa przygotowało około 20 innych osób, które miały jak najdokładniej podrobić podpisy osób ze zbioru, dzięki czemu dla każdej osoby zebrano 24 falszerstwa wykwalifikowane. Podpisy zeskanowano z rozdzielczością 300 dpi w 8-bitowej skali szarości i zapisano w formacie PNG [4]. Podstawowe parametry zbioru zestawiono w tabeli 3.1.

Tabela 3.1. Podstawowe parametry zbioru CEDAR

Parametr	Wartość
liczba osób	55
podpisy prawdziwe na osobę	24
falszerstwa wykwalifikowane na osobę	24
podpisy prawdziwe łącznie	1320
falszerstwa łącznie	1320
wszystkie obrazy	2640

Zbiór CEDAR jest często wykorzystywany w pracach dotyczących weryfikacji podpisu, między innymi w [3, 5], dzięki czemu wyniki uzyskane w niniejszej pracy można porównać z wynikami innych autorów.

W pracy użyto kopii zbioru udostępnionej w serwisie Kaggle [6]. Obrazy podzielone są na dwa katalogi: `full_org` z podpisami prawdziwymi oraz `full_forg` z falszerstwami. Nazwa pliku zawiera numer osoby i numer podpisu, na przykład `original_1_5.png` to piąty prawdziwy podpis osoby nr 1, a `forgeries_1_5.png` to piąte falszerstwo jej podpisu. Według autorów zbioru wszystkie obrazy zapisano w skali szarości, jednak w użytej kopii część plików ma inne tryby kolorów, co opisano w podrozdziale 3.2. Na rys. 3.1 przedstawiono przykładowe podpisy jednej osoby ze zbioru.



Rys. 3.1. Przykładowe podpisy jednej osoby ze zbioru CEDAR: dwa podpisy prawdziwe (a, b) i fałszerstwo wykwalifikowane (c)

3.2. Analiza eksploracyjna danych

Przed przygotowaniem danych do treningu przeprowadzono analizę zbioru, aby sprawdzić jego poprawność i wykryć cechy obrazów, które mogłyby utrudnić trening sieci albo zafałszować wyniki. Analizę wykonano w języku Python z użyciem bibliotek Pillow i NumPy.

Najpierw sprawdzono kompletność zbioru. W katalogu `full_org` znajduje się 1320 obrazów i tyle samo w katalogu `full_forg`, po 24 dla każdej z 55 osób. Dla każdego pliku obliczono skrót MD5 (ang. *Message Digest 5* – algorytm obliczania skrótu), co pozwoliło stwierdzić, że w zbiorze nie ma powtórzonych obrazów. Sprawdzono także, czy wszystkie pliki dają się poprawnie otworzyć, i żaden nie okazał się uszkodzony. Oprócz obrazów w katalogach znajdują się jedynie pliki systemowe `Thumbs.db`, które pominięto.


Następnie sprawdzono tryby kolorów obrazów. Według autorów zbioru wszystkie podpisy zapisano w 8-bitowej skali szarości [4], jednak w użytej kopii podpisy prawdziwe zapisane są w trybach RGBA (ang. *red, green, blue, alpha* – trzy kanały koloru i kanał przezroczystości) i L (skala szarości), a fałszerstwa w trybach P (paleta kolorów) i RGBA. Kolor nie niesie informacji o kształcie podpisu, dlatego wszystkie obrazy przy wczytywaniu zamieniane są na skalę szarości.

Obrazy w zbiorze nie mają wspólnego rozmiaru. Wśród 1320 podpisów prawdziwych występuje 1095 różnych rozmiarów, a wśród fałszerstw 1006. Mediana rozmiaru wynosi 577×349 pikseli dla podpisów prawdziwych i 576×336 pikseli dla fałszerstw (szerokość $\times$ wysokość), a szerokość obrazów waha się od 264 do 888 pikseli. Sieć wymaga obrazów o jednakowym rozmiarze, dlatego wszystkie obrazy trzeba przeskalować. Ponieważ podpisy są wyraźnie szersze niż wyższe (proporcja około 1,7:1), wejście sieci powinno mieć kształt prostokąta, a nie kwadratu. Okazało się również, że rozmiar obrazu niemal jedno-

znacznie wskazuje osobę, do której należy podpis: 85,4% rozmiarów występujących wśród podpisów prawdziwych i 78,1% wśród fałszerstw pojawia się tylko u jednej osoby. Gdyby obrazy nie zostały ujednolicone, się mogłaby nauczyć się rozpoznawać osobę po rozmiarze obrazu, a nie po kształcie podpisu.

Prostokąt obejmujący podpis zajmuje średnio około 60% powierzchni obrazu (60,1% dla podpisów prawdziwych i 58,6% dla fałszerstw), a resztę stanowi puste tło. Za piksele podpisu uznano piksele o jasności mniejszej niż 200. Przy przeskalowaniu całego obrazu do niewielkiego wejścia sieci znaczna jego część przypadłaby więc na tło. Z tego powodu rozważono przycinanie obrazów do prostokąta zawierającego podpis, a wybór sposobu przygotowania obrazu opisano w podrozdziale 4.1.

Najważniejszym wynikiem analizy okazała się różnica w jasności tła między podpisami prawdziwymi a fałszerstwami. Dla każdego obrazu obliczono medianę jasności pikseli, która, ponieważ podpis zajmuje tylko niewielką część pikseli, odpowiada w przybliżeniu jasności tła. Rozkład tej wartości przedstawiono na rys. 3.2.



Rys. 3.2. Rozkład mediany jasności obrazów dla podpisów prawdziwych i fałszerstw w zbiorze CEDAR

Dla podpisów prawdziwych mediana mieści się w przedziale od 234 do 245 (średnio 239,8), a dla fałszerstw od 249 do 255 (średnio 253,5), przy czym 513 z 1320 fałszerstw ma tło idealnie białe. Przedziały te nie nakładają się, więc pojedynczy próg jasności równy 247 pozwala bezbłędnie oddzielić wszystkie podpisy prawdziwe od fałszerstw bez analizowania samego podpisu. Sieć trenowana na takich danych mogłaby wykorzystać tę różnicę zamiast uczyć się cech podpisu, co zawyżyłoby wyniki dla fałszerstw wykwalifikowanych. Na podstawie dostępnych informacji nie da się ustalić, czy różnica ta pochodzi z oryginalnego skanowania, czy z późniejszej konwersji plików. Sposób jej usunięcia opisano w rozdziale 4.

Na koniec sprawdzono, czy do odróżniania podpisów wystarczy proste porównanie obrazów. Obrazy przeskalowano do rozmiaru 128×128 pikseli i dla wszystkich par opisanych w podrozdziale 3.4 obliczono współczynnik korelacji Pearsona między wartościami pikseli. Średnia korelacja wyniosła 0,158 (odchylenie standardowe 0,090) dla par dwóch podpisów prawdziwych tej samej osoby, 0,104 (0,069) dla par z fałszerstwem wykwalifikowanym oraz 0,083 (0,061) dla par podpisów dwóch różnych osób. Rozkłady te w dużym stopniu się nakładają. Korelację potraktowano jako miarę podobieństwa i wybrano próg, przy którym odsetek błędnie odrzuconych par prawdziwych jest równy odsetkowi błędnie zaakceptowanych par fałszywych. Błąd w tym punkcie, nazywany równym współczynnikiem błędów (ang. *equal error rate*, EER), wyniósł 38,0% dla fałszerstw wykwalifikowanych i 32,3% dla fałszerstw losowych. Prosta metoda myli się więc w około jednej trzeciej przypadków, co uzasadnia zastosowanie sieci neuronowej. Wynik ten posłuży również jako punkt odniesienia przy ocenie sieci w rozdziale 5.

3.3. Podział na zbiory niezależne od autora

W weryfikacji podpisu wyróżnia się dwa podejścia. W podejściu zależnym od autora (ang. *writer-dependent*) dla każdej osoby trenuje się osobny model, natomiast w podejściu niezależnym od autora (ang. *writer-independent*) jeden model służy do weryfikacji podpisów dowolnych osób [1]. W drugim przypadku osoby dzieli się na rozłączne zbiory treningowy i testowy, dzięki czemu system nie wymaga ponownego trenowania po dodaniu nowej osoby [3].

W niniejszej pracy zastosowano podejście niezależne od autora. Osoby ze zbioru CEDAR podzielono losowo na trzy rozłączne grupy: 35 osób do zbioru treningowego, 10 do walidacyjnego i 10 do testowego. Liczbę podpisów w każdym ze zbiorów przedstawiono w tabeli 3.2.

Tabela 3.2. Podział zbioru CEDAR na zbiory treningowy, walidacyjny i testowy

Zbiór	Liczba osób	Podpisy prawdziwe	Fałszerstwa
treningowy	35	840	840
walidacyjny	10	240	240
testowy	10	240	240
razem	55	1320	1320

Zbiór treningowy służy do uczenia sieci, zbiór walidacyjny do wyboru progu decyzyjnego i porównywania wariantów modelu, a zbiór testowy wyłącznie do końcowej oceny.

Żadna osoba nie występuje w więcej niż jednym zbiorze, więc wynik na zbiorze testowym pokazuje, jak model radzi sobie z podpisami osób, których wcześniej nie widział. Losowanie wykonano z ustalonym ziarnem generatora liczb losowych (ang. *seed*), a wynik podziału zapisano w pliku, dzięki czemu podział jest za każdym razem taki sam i wszystkie eksperymenty korzystają z tych samych grup osób.

W literaturze stosowane są różne sposoby podziału zbioru CEDAR. Na przykład w pracy [3] do treningu użyto 50 osób, a do testu 5. Z kolei w pracy [4] podzielono podpisy, a nie osoby: 16 podpisów każdej osoby użyto do treningu, a 8 do testu, więc te same osoby występowały w obu zbiorach. Wyniki uzyskane przy różnych sposobach podziału nie są więc bezpośrednio porównywalne, co uwzględniono przy analizie wyników w rozdziale 5.

3.4. Budowa par podpisów

Sieć syjamska uczy się na parach podpisów, z których każda jest oznaczona jako para pozytywna (oba podpisy prawdziwe i należące do tej samej osoby) albo para negatywna. Pary zbudowano osobno w każdym ze zbiorów opisanych w podrozdziale 3.3, tak aby oba podpisy w parze zawsze pochodziły od osób z tego samego zbioru. Wykorzystano trzy rodzaje par.

Pary pozytywne utworzono z podpisów prawdziwych jednej osoby. Z 24 podpisów można utworzyć 276 różnych par, z których dla każdej osoby wylosowano 48. Pary negatywne z fałszerstwami wykwalifikowanymi utworzono, łącząc podpis prawdziwy osoby z fałszerstwem jej podpisu. Spośród 576 możliwych połączeń (24×24) dla każdej osoby wylosowano 24 pary. Pary negatywne z fałszerstwami losowymi utworzono, łącząc każdy z 24 podpisów prawdziwych osoby z losowo wybranym podpisem prawdziwym innej osoby z tego samego zbioru. Taki sposób symulowania fałszerstw losowych, w którym rolę fałszerstwa pełni prawdziwy podpis innej osoby, zastosowano już w pracy, w której zaproponowano sieci syjamskie [2]. W pracy nie uwzględniono fałszerstw prostych, w których fałszerz zna imię i nazwisko osoby, ale nie zna jej podpisu [1], ponieważ zbiór CEDAR ich nie zawiera.

Dla każdej osoby powstało więc 48 par pozytywnych i 48 par negatywnych (24 z fałszerstwami wykwalifikowanymi i 24 z fałszerstwami losowymi), dzięki czemu obie klasy są równoliczne i sieć nie faworyzuje żadnej z nich. Liczbę par w poszczególnych zbiorach przedstawiono w tabeli 3.3.

Pary zapisano w plikach CSV (ang. *comma-separated values* – wartości rozdzielone przecinkami), w których dla każdej pary podano nazwy obu plików, numery osób, rodzaj

Tabela 3.3. Liczba par podpisów w zbiorach treningowym, walidacyjnym i testowym

Zbiór	Pozytywne	Wykwalifikowane	Losowe	Razem
treningowy	1680	840	840	3360
walidacyjny	480	240	240	960
testowy	480	240	240	960
razem	2640	1320	1320	5280

pary oraz zbiór, do którego należy. Losowanie wykonano z ustalonymi ziarnami generatora liczb losowych, dzięki czemu pary można odtworzyć. Po zapisaniu pliku sprawdzono automatycznie: dla każdej pary porównano numer osoby odczytany z nazwy pliku z numerem zapisanym w pliku CSV, sprawdzono, czy oba podpisy należą do właściwego zbioru, oraz czy rodzaj pary jest zgodny z osobami, od których pochodzą podpisy. Sprawdzenie nie wykazało żadnych błędów.

4. Model sieci syjamskiej

W rozdziale opisano kolejne elementy proponowanego rozwiązania: przygotowanie obrazów przed podaniem ich do sieci, budowę sieci syjamskiej, funkcję straty oraz sposób treningu.

4.1. Przygotowanie obrazów

Analiza opisana w podrozdziale 3.2 pokazała, że obrazy w zbiorze CEDAR różnią się rozmiarem i trybem kolorów, a podpisy prawdziwe i fałszerstwa różnią się jasnością tła. Przed podaniem do sieci każdy obraz przechodzi więc przez te same kroki, wykonywane w podanej kolejności:

- 1) zamiana na skalę szarości,
- 2) usunięcie tła metodą Otsu,
- 3) wyrównanie ciemności atramentu,
- 4) dopasowanie do rozmiaru wejścia sieci bez zniekształcania proporcji,
- 5) odwrócenie jasności i przeskalowanie wartości do przedziału od 0 do 1.

Wszystkie kroki zaimplementowano w języku Python z użyciem bibliotek OpenCV i NumPy. Kolejne kroki dla przykładowego podpisu prawdziwego i fałszerstwa przedstawiono na rys. 4.1.


Usunięcie tła

Do oddzielenia podpisu od tła użyto metody Otsu [7], która automatycznie wyznacza próg jasności na podstawie histogramu obrazu. Metoda dzieli piksele progiem k na dwie grupy: piksele ciemniejsze od progu (podpis) i piksele jaśniejsze (tło). Dla każdego możliwego progu obliczana jest wariancja międzyklasowa

$$\sigma_B^2(k) = \omega_0(k) \omega_1(k) (\mu_1(k) - \mu_0(k))^2, \quad (4.1)$$

gdzie ω_0 i ω_1 oznaczają udział pikseli w każdej z grup, a μ_0 i μ_1 ich średnią jasność. Wybierany jest próg, dla którego wartość σ_B^2 jest największa, czyli taki, przy którym obie grupy najbardziej różnią się jasnością [7].

Piksele jaśniejsze od wyznaczonego progu otrzymują wartość 255 (kolor biały), a piksele podpisu zachowują swoją jasność, tak jak w pracy [5]. Obraz nie jest więc binaryzowany, a sieć dostaje informację o odcieniach kresek. Wyznaczone progi wynosiły od 170 do 210 dla podpisów prawdziwych i od 174 do 226 dla fałszerstw. Po tym kroku mediana jasności



Rys. 4.1. Kolejne kroki przygotowania obrazu dla podpisu prawdziwego (dwa górne wiersze) i fałszerstwa wykwalifikowanego (dwa dolne wiersze) osoby nr 1: a) oryginał, b) po usunięciu tła, c) po wyrównaniu atramentu, d) po dopasowaniu do rozmiaru 128×256 , e) po odwróceniu jasności

każdego z 2640 obrazów wynosi 255, więc różnica jasności tła opisana w podrozdziale 3.2 zostaje usunięta. Wpływ tego kroku na wyniki sieci zbadano w rozdziale 5.

Wybór obszaru obrazu

Rozważono trzy sposoby wyboru obszaru obrazu, który jest następnie dopasowywany do wejścia sieci. W pierwszym obraz jest przycinany do najmniejszego prostokąta zawierającego wszystkie piksele podpisu, czyli piksele o jasności mniejszej niż 255 po usunięciu tła. Podpis zajmuje wtedy możliwie dużą część wejścia sieci, ale każdy podpis jest skalowany inaczej, więc informacja o jego rozmiarze zostaje utracona. W drugim do wejścia sieci dopasowywany jest cały obraz po usunięciu tła, podobnie jak w pracy [3]. W trzecim podpis jest umieszczany na białym tle o rozmiarze 730×1460 pikseli, większym niż największy podpis w zbiorze, tak aby jego środek masy znalazł się w środku tła, jak w pracy [5]. Wszystkie

podpisy są wtedy skalowane w tej samej skali, ale na wejściu sieci zajmują niewielką część obrazu.

Warianty porównano doświadczalnie, a wyniki przedstawiono w rozdziale 5. Najmniejszy błąd na zbiorze walidacyjnym uzyskano dla całego obrazu, dlatego ten wariant przyjęto jako podstawowy.

Wyrównanie ciemności atramentu

Po usunięciu tła okazało się, że podpisy prawdziwe i fałszerstwa różnią się także ciemnością kresek. Podpisy jednej osoby zbierano w jednej sesji tym samym długopisem, a fałszerstwa powstawały w innych warunkach. Mediana różnicy ciemności atramentu wynosiła 3 dla par dwóch podpisów prawdziwych tej samej osoby i 18 dla par z fałszerstwem. Porównanie samej ciemności atramentu, bez analizy kształtu podpisu, dawało dla fałszerstw wykwalifikowanych EER równy 21,1%.

Aby ograniczyć tę różnicę, jasność pikseli podpisu jest przeskalowywana tak, aby mediana ich ciemności (różnicy między 255 a jasnością piksela) była taka sama w każdym obrazie. Po przeskalowaniu mediana jasności pikseli podpisu wynosi 100. Kształt kresek i różnice odcieni w obrębie podpisu zostają zachowane. Po tej zmianie EER uzyskany na podstawie samej ciemności atramentu wzrósł do 36,7%. Różnica nie zniknęła całkowicie, co prawdopodobnie wynika z różnej grubości kresek przy użyciu innego długopisu.

Dopasowanie do rozmiaru wejścia

Jako rozmiar wejścia sieci przyjęto 128×256 pikseli (wysokość $\times$ szerokość). Obraz jest zmniejszany lub powiększany z zachowaniem proporcji tak, aby zmieścił się w tym prostokącie, a wolne miejsce jest dopełniane białym tłem. Obraz znajduje się w środku wejścia sieci. Proporcji nie zmieniano, ponieważ rozciągnięcie obrazu zmieniłoby kształt liter, inaczej niż w pracy [3], w której wszystkie obrazy skalowano do jednego rozmiaru bez zachowania proporcji. Przy zmniejszaniu użyto interpolacji `INTER_AREA`, która uśrednia piksele i nie gubi cienkich kresek.

Rozmiar wejścia wybrano na podstawie porównania czterech wariantów: 64×128 , 128×216 , 128×256 i 256×512 pikseli, opisanego w rozdziale 5. Wariant 128×216 ma proporcję około 1,7, taką jak całe obrazy (podrozdział 3.2), więc nie powstają w nim białe pasy po bokach, jednak nie dał on poprawy. Mniejsze wejście 64×128 dało większy błąd na zbiorze walidacyjnym. Wejście 256×512 dało mniejszy błąd na zbiorze walidacyjnym, ale nie na zbiorze testowym, a jeden trening trwał ponad osiem razy dłużej, dlatego

pozostano przy rozmiarze 128×256 . Jako rozmiar wejścia sieci przyjęto 128×256 pikseli (wysokość $\times$ szerokość). Obraz jest zmniejszany lub powiększany z zachowaniem proporcji tak, aby zmieścił się w tym prostokącie, a wolne miejsce jest dopełniane białym tłem. Obraz znajduje się w środku wejścia sieci. Proporcji nie zmieniano, ponieważ rozciągnięcie obrazu zmieniałoby kształt liter, inaczej niż w pracy [3], w której wszystkie obrazy skalowano do jednego rozmiaru bez zachowania proporcji. Proporcję 1:2 dobrano na początku prac do obrazów przyciętych do podpisu, dla których mediana stosunku szerokości do wysokości wynosiła około 2,1. Całe obrazy mają proporcję około 1,7 (podrozdział 3.2), więc po ich bokach pozostają wąskie białe pasy. Wpływ rozmiaru wejścia na wyniki zbadano w rozdziale 5. Przy zmniejszaniu użyto interpolacji `INTER_AREA`, która uśrednia piksele i nie gubi cienkich kresek.

Odwrócenie jasności

Na koniec jasność każdego piksela p jest zamieniana na wartość $1 - p/255$. Tło ma wtedy wartość 0, a piksele podpisu wartości bliskie 1, tak jak w pracach [3, 5]. Taka postać jest wygodna dla sieci, ponieważ puste miejsca obrazu mają wartość zero, tak samo jak dopełnienie stosowane przy obrotach i przesunięciach obrazu w czasie augmentacji danych (podrozdział 4.3).

Wpływ przygotowania obrazów na metodę porównawczą

Prosta metoda porównawcza z podrozdziału 3.2 została powtórzona na obrazach przygotowanych w opisany sposób. EER wyniósł 38,0% dla fałszerstw wykwalifikowanych i 32,0% dla fałszerstw losowych, czyli prawie tyle samo co dla obrazów nieprzetworzonych (38,0% i 32,3%). Przygotowanie obrazów nie ułatwia więc zadania prostej metodzie, która nadal myli się w około jednej trzeciej przypadków. Gdy obrazy dodatkowo przycinano do prostokąta zawierającego podpis, EER dla fałszerstw wykwalifikowanych wzrastał do 42,1%. Wskazuje to, że położenie i rozmiar podpisu na obrazie niosą pewną informację przydatną do wykrywania fałszerstw, co omówiono w rozdziale 5.

4.2. Budowa sieci syjamskiej

Sieć syjamska składa się z dwóch jednakowych gałęzi, które mają wspólne wagi [2]. Każda gałąź zamienia obraz podpisu na wektor liczb, nazywany wektorem cech, a następnie obliczana jest odległość między wektorami obu podpisów. Dzięki wspólnym wagom oba podpisy

są przetwarzane w dokładnie ten sam sposób, a w implementacji wystarczy jedna sieć, przez którą kolejno przechodzą oba obrazy pary.

Gałąź sieci jest splotową siecią neuronową (ang. *convolutional neural network*, CNN) złożoną z czterech bloków. Każdy blok zawiera warstwę splotową, normalizację wsadową (ang. *batch normalization*) [8], funkcję aktywacji ReLU (ang. *rectified linear unit* – funkcja zwracająca wartość wejścia dla wartości dodatnich i zero dla ujemnych) oraz warstwę łączącą (ang. *max pooling*), która zmniejsza wysokość i szerokość mapy cech dwukrotnie. Pierwsza warstwa splotowa ma filtry o rozmiarze 5×5 , a pozostałe 3×3 . Po czterech blokach mapy cech są uśredniane do siatki 2×4 , a otrzymane 1024 wartości przechodzą przez warstwę porzucania (ang. *dropout*) [9] i warstwę w pełni połączoną, która zwraca wektor cech o długości 128. Wektor jest na końcu normalizowany do długości 1, dzięki czemu odległość między dwoma wektorami zawsze mieści się w przedziale od 0 do 2. Budowę jednej gałęzi przedstawiono w tabeli 4.1.

Tabela 4.1. Budowa jednej gałęzi sieci syjamskiej dla wejścia o rozmiarze 128×256

Warstwa	Parametry	Rozmiar wyjścia	Liczba wag
wejście	–	$1 \times 128 \times 256$	–
blok 1	splot 5×5 , 32 filtry	$32 \times 64 \times 128$	896
blok 2	splot 3×3 , 64 filtry	$64 \times 32 \times 64$	18 624
blok 3	splot 3×3 , 128 filtrów	$128 \times 16 \times 32$	74 112
blok 4	splot 3×3 , 128 filtrów	$128 \times 8 \times 16$	147 840
uśrednianie	siatka 2×4	1024	–
porzucanie	$p = 0,3$	1024	–
w pełni połączona	$1024 \rightarrow 128$	128	131 200
normalizacja	długość wektora 1	128	–
razem			372 672

Uśrednianie do stałej siatki 2×4 sprawia, że liczba wartości przekazywanych do warstwy w pełni połączonej nie zależy od rozmiaru obrazu wejściowego. Tę samą sieć można więc stosować bez zmian dla różnych rozmiarów wejścia, co wykorzystano w rozdziale 5. Normalizacja wsadowa w czasie treningu korzysta ze średniej i wariancji obliczonych na bieżącej porcji danych, a w czasie oceny z wartości uśrednionych podczas całego treningu [8]. Warstwa porzucania w czasie treningu losowo wyłącza 30% wartości, co utrudnia sieci zapamiętanie danych treningowych, a w czasie oceny jest nieaktywna [9].

Dla pary obrazów x_1 i x_2 sieć zwraca odległość euklidesową między ich wektorami cech

$$D = \|f(x_1) - f(x_2)\|_2, \quad (4.2)$$

gdzie f oznacza gałąź sieci. Mała odległość oznacza, że podpisy są podobne, a duża, że się różnią.

4.3. Funkcja straty i trening

Funkcja straty

Sieć trenowano funkcją straty kontrastowej (ang. *contrastive loss*) [10]. Dla pary o etykiecie y ($y = 1$ dla dwóch podpisów tej samej osoby i $y = 0$ dla pary negatywnej) i odległości D ze wzoru (4.2) strata wynosi

$$L = yD^2 + (1 - y) (\max(0, m - D))^2, \quad (4.3)$$

gdzie m jest marginesem. Dla par pozytywnych strata rośnie wraz z odległością, więc sieć uczy się zbliżać do siebie wektory podpisów tej samej osoby. Dla par negatywnych strata jest dodatnia tylko wtedy, gdy odległość jest mniejsza od marginesu, więc sieć oddala od siebie wektory różnych podpisów, ale nie dalej niż na odległość m . Bez składnika dla par negatywnych sieć mogłaby przypisać wszystkim obrazom ten sam wektor i uzyskać zerową stratę [10]. Przyjęto margines $m = 1$, tak jak w pracy [3]. W porównaniu z pracą [10] zamieniono oznaczenie etykiet i pominięto czynnik $\frac{1}{2}$ przed oboma składnikami, co nie zmienia położenia minimum funkcji straty.

Przebieg treningu

Do optymalizacji wag użyto algorytmu Adam [11] z krokiem uczenia 0,001, czyli wartością zalecaną przez autorów metody, oraz z karą za duże wartości wag (ang. *weight decay*) równą 10^{-4} . Sieć trenowano przez 30 epok, w porcjach po 32 pary. Na początku każdej epoki losowano nowe pary treningowe: dla każdej osoby 48 par pozytywnych, 24 pary z fałszerstwem wykwalifikowanym i 24 pary losowe, w taki sam sposób jak w podrozdziale 3.4. Dzięki temu w kolejnych epokach sieć widzi różne połączenia podpisów, a klasy pozostają równoliczne. Pary walidacyjne i testowe były stałe.

W czasie treningu stosowano augmentację danych, czyli niewielkie losowe zmiany obrazów, które zwiększają różnorodność danych treningowych [12]. Każdy obraz pary był niezależnie obracany o kąt do $\pm 5^\circ$, przesuwany o maksymalnie 5% szerokości i wysokości oraz zmniejszany do 85–100% rozmiaru, a puste miejsca wypełniano wartością tła. Zastosowano tylko małe kąty obrotu, ponieważ duże obroty mogą zmienić znaczenie obrazu [12]. Nie stosowano powiększania, które ucinęło końce podpisów, ani pocieniania kresek, po którym zniknęły cienkie linie. Augmentację stosowano wyłącznie do zbioru treningowego.

Wybór modelu i progu

Po każdej epoce obliczano EER na wszystkich parach zbioru walidacyjnego i zapisywano model z epoki o najmniejszym błędzie. Próg decyzyjny wyznaczano na zbiorze walidacyjnym, na parach pozytywnych i parach z fałszerstwami wykwalifikowanymi, w punkcie równego współczynnika błędów. Zbiór testowy wykorzystywano tylko do końcowej oceny wybranego modelu.

Każdy wariant trenowano trzykrotnie, z różnymi ziarnami generatora liczb losowych, które decydują o początkowych wagach sieci, losowaniu par i augmentacji. Wyniki podawane są jako średnia i odchylenie standardowe z trzech treningów. Sprawdzono, że ponowny trening z tym samym ziarnem daje identyczny wynik. Sieć zaimplementowano w bibliotece PyTorch i trenowano na karcie graficznej NVIDIA GeForce RTX 4070 Laptop, a jeden trening trwał około 9 minut.

5. Badania eksperymentalne i wyniki

6. Podsumowanie i wnioski końcowe

Literatura

- [1] Hafemann L.G., Sabourin R., Oliveira L.S.: Offline Handwritten Signature Verification — Literature Review. 7th International Conference on Image Processing Theory, Tools and Applications (IPTA), 2017.
- [2] Bromley J., Guyon I., LeCun Y., Säckinger E., Shah R.: Signature Verification using a „Siamese” Time Delay Neural Network. Advances in Neural Information Processing Systems 6 (NIPS 1993), str. 737–744.
- [3] Dey S., Dutta A., Toledo J.I., Ghosh S.K., Lladós J., Pal U.: SigNet: Convolutional Siamese Network for Writer Independent Offline Signature Verification. arXiv:1707.02131, 2017.
- [4] Kalera M.K., Srihari S.N., Xu A.: Offline Signature Verification and Identification Using Distance Statistics. International Journal of Pattern Recognition and Artificial Intelligence, vol. 18, nr 7, 2004, str. 1339–1360.
- [5] Hafemann L.G., Sabourin R., Oliveira L.S.: Learning Features for Offline Handwritten Signature Verification using Deep Convolutional Neural Networks. Pattern Recognition, vol. 70, 2017, str. 163–176.
- [6] CEDAR Signature Dataset, <https://www.kaggle.com/datasets/shreelakshmigp/cedardataset>. Dostęp 29.09.2026.
- [7] Otsu N.: A Threshold Selection Method from Gray-Level Histograms. IEEE Transactions on Systems, Man, and Cybernetics, vol. SMC-9, nr 1, 1979, str. 62–66.
- [8] Ioffe S., Szegedy C.: Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. Proceedings of the 32nd International Conference on Machine Learning (ICML), PMLR vol. 37, 2015, str. 448–456.
- [9] Srivastava N., Hinton G., Krizhevsky A., Sutskever I., Salakhutdinov R.: Dropout: A Simple Way to Prevent Neural Networks from Overfitting. Journal of Machine Learning Research, vol. 15, 2014, str. 1929–1958.
- [10] Hadsell R., Chopra S., LeCun Y.: Dimensionality Reduction by Learning an Invariant Mapping. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2006, str. 1735–1742.

- [11] Kingma D.P., Ba J.: Adam: A Method for Stochastic Optimization. International Conference on Learning Representations (ICLR), 2015.
- [12] Shorten C., Khoshgoftaar T.M.: A survey on Image Data Augmentation for Deep Learning. Journal of Big Data, vol. 6, nr 60, 2019.

STRESZCZENIE PRACY DYPLOMOWEJ INŻYNIERSKIEJ

**ZASTOSOWANIE ALGORYTMÓW SZTUCZNEJ INTELIGENCJI DO ROZPOZNAWANIA
AUTENTYCZNOŚCI PODPISU**

Autor: Maciej Pereślucha, nr albumu: EF-177139

Opiekun: dr inż. Paweł Górka

Słowa kluczowe: max. 5 słów kluczowych w 2 wierszach, oddzielanych przecinkami

Treść streszczenia po polsku

BSC THESIS ABSTRACT

**APPLICATION OF ARTIFICIAL INTELLIGENCE ALGORITHMS FOR SIGNATURE
AUTHENTICITY RECOGNITION**

Author: Maciej Pereślucha, Student's ID: EF-177139

Supervisor: Paweł Górka, PhD, Eng.

Key words: max. five keywords in English

Treść streszczenia po angielsku