

WYDZIAŁ
ELEKTROTECHNIKI
I INFORMATYKI
POLITECHNIKI RZESZOWSKIEJ

Maciej Pereślucha

Zastosowanie algorytmów sztucznej inteligencji do rozpoznawania autentyczności podpisu

PRACA INŻYNIERSKA

Opiekun pracy:
dr inż. Paweł Górka

Rzeszów, 2026

Spis treści

Wykaz symboli, oznaczeń i skrótów **5**

1. Wprowadzenie **7**

2. Metody weryfikacji podpisu – przegląd literatury **9**

2.1. Weryfikacja podpisu odręcznego 9

2.2. Miary oceny systemów weryfikacji 10

2.3. Metody weryfikacji podpisów statycznych 11

2.4. Sieci splotowe 13

2.5. Sieci syjamskie i funkcja straty kontrastowej 13

2.6. Uczenie na skróty 15

3. Zbiór danych i jego przygotowanie **17**

3.1. Zbiór CEDAR 17

3.2. Analiza eksploracyjna danych 18

3.3. Podział na zbiory niezależne od autora 20

3.4. Budowa par podpisów 21

4. Model sieci syjamskiej **23**

4.1. Przygotowanie obrazów 23

4.2. Budowa sieci syjamskiej 26

4.3. Funkcja straty i trening 27

5. Badania eksperymentalne i wyniki **31**

5.1. Miary oceny i przebieg badań 31

5.2. Porównanie wariantów modelu 32

5.3. Wpływ różnic niezwiązanych z kształtem podpisu 34

5.4. Walidacja krzyżowa i wynik końcowy 36

5.5. Porównanie z wynikami z literatury 40

6. Podsumowanie i wnioski końcowe **41**

Literatura **42**

Wykaz symboli, oznaczeń i skrótów

AER	ang. *average error rate* – średni współczynnik błędów
CEDAR	Center of Excellence for Document Analysis and Recognition – ośrodek Uniwersytetu w Buffalo, autor zbioru podpisów
CNN	ang. *convolutional neural network* – splotowa sieć neuronowa
CSV	ang. *comma-separated values* – format pliku tekstowego z wartościami rozdzielonymi przecinkami
EER	ang. *equal error rate* – równy współczynnik błędów
FAR	ang. *false acceptance rate* – współczynnik błędnych akceptacji
FRR	ang. *false rejection rate* – współczynnik błędnych odrzuceń
MD5	ang. *Message Digest 5* – algorytm obliczania skrótu pliku
ReLU	ang. *rectified linear unit* – funkcja aktywacji zwracająca wartość wejścia dla wartości dodatnich i zero dla ujemnych
RGBA	ang. *red, green, blue, alpha* – zapis obrazu w trzech kanałach koloru i kanale przezroczystości
SVM	ang. *support vector machine* – maszyna wektorów nośnych

1. Wprowadzenie

Podpis odręczny jest jednym z najczęściej używanych sposobów potwierdzania tożsamości, na przykład w bankach, u notariusza czy w urzędach. Sprawdzaniem, czy podpis jest prawdziwy, zajmują się zwykle biegli grafolodzy, jednak taka ocena zajmuje dużo czasu i w pewnym stopniu zależy od doświadczenia osoby, która ją wykonuje. Automatyczna weryfikacja podpisu jest badana od kilkudziesięciu lat, ale nadal pozostaje problemem otwartym. Rozwój uczenia głębokiego sprawił, że sieci neuronowe potrafią same nauczyć się cech, po których można odróżnić podpisy różnych osób, bez ręcznego projektowania tych cech [1].

Najprostszym pomysłem byłoby nauczenie sieci rozpoznawania podpisów każdej osoby osobno, tak jak w zwykłym zadaniu klasyfikacji. Takie podejście ma jednak dwie wady. Po pierwsze, od jednej osoby dostępnych jest zwykle niewiele podpisów — w zbiorze użytym w tej pracy są to 24 podpisy na osobę. Po drugie, dodanie do systemu każdej nowej osoby wymagałoby ponownego trenowania modelu. Rozwiązaniem jest sieć syjamska, która składa się z dwóch jednakowych podsieci i zamiast odpowiadać na pytanie, do kogo należy podpis, porównuje ze sobą dwa podpisy i mierzy, jak bardzo są do siebie podobne [2]. Dzięki temu sieć może być stosowana także do osób, których podpisów nie widziała podczas treningu [3].

W pracy wykorzystano podpisy w postaci zeskanowanych obrazów. Taki wariant nazywa się weryfikacją statyczną (ang. *offline*), w odróżnieniu od weryfikacji dynamicznej (ang. *online*), w której podpis składany jest na tablecie rejestrującym na przykład prędkość ruchu pióra. Na obrazie tych informacji nie ma, widoczny jest tylko kształt podpisu. Najtrudniejsze do wykrycia są fałszerstwa wykwalifikowane, czyli podpisy podrobione przez osobę, która wcześniej ćwiczyła naśladowanie oryginału [1]. Wstępna analiza danych wykonana w ramach pracy pokazała, że proste porównanie obrazów piksel po pikselu myli się w około jednej trzeciej przypadków, dlatego potrzebna jest bardziej zaawansowana metoda.

Celem pracy było opracowanie systemu, który na podstawie zeskanowanego obrazu sprawdza, czy podpis jest autentyczny, oraz ocena jego skuteczności. System oparto na sieci syjamskiej i zaprojektowano tak, aby działał również dla osób, których podpisy nie były używane podczas treningu. Zakres pracy obejmował:

- przegląd literatury dotyczącej weryfikacji podpisu i sieci syjamskich,
- analizę zbioru podpisów CEDAR,

– przygotowanie danych, w tym podział osób na osobne zbiory treningowy, walidacyjny i testowy oraz utworzenie par podpisów,
– implementację sieci syjamskiej w języku Python,
– trening sieci i ocenę jej skuteczności na zbiorze testowym,
– analizę otrzymanych wyników.

2. Metody weryfikacji podpisu – przegląd literatury

W rozdziale przedstawiono podstawowe pojęcia związane z weryfikacją podpisu oraz metody opisane w literaturze. Najpierw omówiono samo zadanie weryfikacji i miary używane do oceny systemów, a następnie klasyczne metody oparte na ręcznie projektowanych cechach oraz metody wykorzystujące sieci neuronowe. Osobno opisano sieci splotowe i sieci syjamskie, na których oparto rozwiązanie zaproponowane w pracy, a na końcu zjawisko uczenia na skróty, które okazało się ważne przy interpretacji wyników.

2.1. Weryfikacja podpisu odręcznego

Podpis jako cecha biometryczna

Biometria to automatyczne rozpoznawanie osób na podstawie ich cech fizjologicznych lub behawioralnych [4]. Do cech fizjologicznych należą na przykład odcisk palca, twarz czy tęczówka oka, a do behawioralnych głos i podpis odręczny [1]. Podpis jest powszechnie akceptowanym sposobem potwierdzania tożsamości w sprawach urzędowych, prawnych i handlowych [4]. Jako cecha behawioralna zmienia się jednak w czasie i zależy od stanu fizycznego i emocjonalnego osoby, a u niektórych osób nawet kolejne podpisy wyraźnie się od siebie różnią [4].

System biometryczny może działać w jednym z dwóch trybów [4]. W trybie weryfikacji użytkownik podaje swoją tożsamość, a system porównuje jego próbkę tylko z wzorcem tej jednej osoby i sprawdza, czy podana tożsamość jest prawdziwa. W trybie identyfikacji tożsamość nie jest podawana, a system porównuje próbkę z wzorcami wszystkich zapisanych osób, aby ustalić, do kogo należy. Niniejsza praca dotyczy weryfikacji: dla dwóch podpisów należy rozstrzygnąć, czy pochodzą od tej samej osoby.

Weryfikacja dynamiczna i statyczna

W zależności od sposobu pozyskania podpisu wyróżnia się weryfikację dynamiczną (ang. *online*) i statyczną (ang. *offline*) [1]. W weryfikacji dynamicznej podpis składany jest na urządzeniu, takim jak tablet, które zapisuje położenie pióra w kolejnych chwilach czasu, a czasem także jego nacisk i nachylenie. W weryfikacji statycznej podpis jest pozyskiwany po zakończeniu pisania, zwykle przez zeskanowanie dokumentu, i ma postać obrazu [1]. Na obrazie brakuje informacji dynamicznej o przebiegu pisania [5]. Systemy dynamiczne osiągają dzięki tej informacji zwykle lepsze wyniki, ale wymagają specjalnego sprzętu, a w wielu

sytuacjach, na przykład przy sprawdzaniu czeków i dokumentów, dostępny jest wyłącznie obraz podpisu [3].

Rodzaje fałszerstw

Fałszerstwa podpisów dzieli się zwykle na trzy rodzaje [1]. W fałszerstwie losowym fałszerz nie ma żadnych informacji o osobie ani o jej podpisie i składa własny podpis, który ma zupełnie inny kształt niż podpis prawdziwy. W fałszerstwie prostym fałszerz zna imię i nazwisko osoby, ale nie zna jej podpisu. W fałszerstwie wykwalifikowanym fałszerz ma dostęp do prawdziwego podpisu i często ćwiczy jego naśladowanie, dlatego takie fałszerstwa są najbardziej podobne do podpisów prawdziwych i najtrudniejsze do wykrycia [1].

Trudności i podejścia do weryfikacji

Jedną z głównych trudności jest duża zmienność podpisów jednej osoby, większa niż w przypadku cech fizjologicznych, takich jak odcisk palca [1]. Jednocześnie fałszerstwa wykwalifikowane są bardzo podobne do podpisów prawdziwych, więc różnice między klasami są małe. Dodatkowo w rzeczywistym zastosowaniu dla osób zapisanych w systemie dostępne są tylko ich podpisy prawdziwe, i to zwykle w niewielkiej liczbie, a system musi mimo to odrzucać fałszerstwa [1].

Systemy weryfikacji dzieli się na zależne i niezależne od autora [1]. W podejściu zależnym od autora (ang. *writer-dependent*) dla każdej osoby trenowany jest osobny model, uczony na jej podpisach prawdziwych i na podpisach prawdziwych innych osób, które pełnią rolę fałszerstw losowych. W podejściu niezależnym od autora (ang. *writer-independent*) jeden model służy do weryfikacji podpisów wszystkich osób: uczy się porównywać podpis badany z podpisem wzorcowym, a do treningu i testu używa się rozłącznych grup osób [1]. Podejście zależne od autora jest częściej spotykane w literaturze i zwykle daje lepsze wyniki, ale jego złożoność rośnie wraz z liczbą osób w systemie [6]. Podejście niezależne od autora nie wymaga ponownego trenowania modelu po dodaniu nowej osoby, co ma znaczenie na przykład w banku, w którym nowi klienci pojawiają się codziennie [3].

2.2. Miary oceny systemów weryfikacji

System weryfikacji porównuje wynik dopasowania dwóch próbek z progiem decyzyjnym i na tej podstawie uznaje je za pochodzące od tej samej osoby albo od różnych osób [4]. Może przy tym popełnić dwa rodzaje błędów: zaakceptować próbki różnych osób albo odrzucić próbki tej samej osoby [4]. Opisują je współczynnik błędnych akceptacji FAR (ang. *false*

acceptance rate) i współczynnik błędnych odrzuceń FRR (ang. *false rejection rate*) [5]:

$$\mathrm{FAR}(t) = \frac{N_{\mathrm{FA}}(t)}{N_{\mathrm{neg}}}, \qquad \mathrm{FRR}(t) = \frac{N_{\mathrm{FR}}(t)}{N_{\mathrm{poz}}}, \tag{2.1}$$

gdzie t oznacza próg, $N_{\mathrm{FA}}(t)$ liczbę błędnie zaakceptowanych par próbek różnych osób, $N_{\mathrm{FR}}(t)$ liczbę błędnie odrzuconych par próbek tej samej osoby, a N_{neg} i N_{poz} liczbę wszystkich par obu rodzajów. W pracy [4] te same błędy nazwano współczynnikami fałszywego dopasowania i fałszywego niedopasowania.

Oba współczynniki zależą od progu: przesunięcie progu zmniejsza jeden z nich, ale zwiększa drugi [4]. W systemach o wysokim poziomie bezpieczeństwa ważniejszy jest mały FAR, a w innych zastosowaniach można dopuścić więcej błędnych akceptacji w zamian za mniej odrzuceń prawdziwych użytkowników [4]. Do porównywania systemów niezależnie od wybranego progu używa się równego współczynnika błędów EER, czyli wartości błędu w punkcie, w którym FAR i FRR są sobie równe [5]. W pracach dotyczących podpisów podaje się też osobno odsetek zaakceptowanych fałszerstw wykwalifikowanych oraz średni błąd AER (ang. *average error rate*), czyli średnią z FRR i tego odsetka [1].

Porównywanie wyników z różnych prac jest utrudnione. Wiele badań prowadzono na prywatnych zbiorach danych, a nawet przy użyciu tego samego zbioru prace różnią się sposobem treningu, na przykład liczbą podpisów wzorcowych, oraz sposobem oceny, na przykład podawanymi miarami [1].

2.3. Metody weryfikacji podpisów statycznych

Metody oparte na cechach projektowanych ręcznie

Klasyczny system weryfikacji podpisu składa się z trzech etapów: przygotowania obrazu, wyznaczenia cech i klasyfikacji [1]. Przygotowanie obrazu obejmuje między innymi usuwanie szumu oraz normalizację rozmiaru, na przykład przez przycięcie obrazu do prostokąta zawierającego podpis albo umieszczenie podpisu w środku ramki o stałym rozmiarze [1].

Przez wiele lat główny wysiłek badaczy skupiał się na projektowaniu cech, które dobrze opisują podpis [1]. Stosowano między innymi cechy geometryczne (wysokość, szerokość, pole podpisu), cechy kierunkowe opisujące kierunek kresek, przekształcenia matematyczne obrazu, cechy teksturowe, w tym lokalne wzorce binarne (ang. *local binary patterns*), oraz cechy pseudodynamiczne, które próbują odtworzyć z obrazu informację o przebiegu pisania [1]. Cechy mogą opisywać cały podpis albo jego fragmenty, wyznaczane najczęściej przez podział obrazu na siatkę. Mimo wielu propozycji żaden sposób wyznaczania cech nie

okazał się wyraźnie najlepszy dla weryfikacji podpisu [6]. Do klasyfikacji używano głównie ukrytych modeli Markowa, maszyn wektorów nośnych (ang. *support vector machine*, SVM) oraz sieci neuronowych [1].

Przykładem metody klasycznej jest praca [5], w której przedstawiono zbiór CEDAR. Z obrazów zbinaryzowanych wyznaczano tam cechy gradientowe, strukturalne i opisujące wklęsłości podpisu, tworząc wektor 1024 bitów. Podobieństwo dwóch podpisów obliczano miarą korelacji, a decyzję podejmowano na podstawie rozkładów podobieństwa par podpisów tej samej osoby i par z fałszerstwem. Na zbiorze CEDAR uzyskano EER równy 21,9%, przy czym do treningu i testu użyto różnych podpisów tych samych osób [5].

Metody oparte na uczeniu cech

W ostatnich latach coraz częściej stosuje się metody, które nie wymagają projektowania cech, ponieważ uczą się ich bezpośrednio z pikseli obrazu [1]. W pracy [6] sieć splotową wytrenowano na podpisach jednej grupy osób, ucząc ją rozpoznawać, do kogo należy podpis, a w jednym z wariantów także odróżniać podpisy prawdziwe od fałszerstw. Wytrenowana sieć służyła następnie do wyznaczania cech podpisów innych osób, a dla każdej z nich trenowano osobny klasyfikator SVM. Cechy uczone są więc niezależnie od autora, a klasyfikacja zależnie od autora. Przed podaniem do sieci podpis umieszczano w środku dużego obrazu według środka masy, usuwano tło metodą Otsu, odwracano jasność i zmniejszano obraz do rozmiaru wejścia sieci [6]. Metoda ta osiągnęła najlepsze wówczas wyniki na kilku zbiorach podpisów, w tym na zbiorze CEDAR, na którym EER wyniósł 4,63% przy 12 podpisach wzorcowych każdej osoby [6].

Wyniki wybranych metod na zbiorze CEDAR zestawiono w tabeli 2.1, opracowanej na podstawie przeglądu [1]. Wszystkie wymienione metody poza metodą z uczeniem cech opierają się na cechach projektowanych ręcznie.

Tabela 2.1. Wyniki wybranych metod na zbiorze CEDAR według [1] (błąd AER, a dla uczenia cech EER, w procentach)

Cechy i klasyfikator	Podejście	Podpisy wzorcowe	Błąd
dopasowanie grafów	zależne	16	7,9
morfologia podpisu (SVM)	niezależne	1	11,81
cechy otoczenia (sieć neuronowa)	niezależne	1	8,33
kody łańcuchowe (SVM)	zależne	12	7,84
transformata curvelet (jednoklasowa SVM)	zależne	12	5,6
uczenie cech siecią splotową (SVM)	zależne	12	4,63

2.4. Sieci splotowe

Sieci splotowe (ang. *convolutional neural network*, CNN) są rodzajem sieci neuronowych przeznaczonym do przetwarzania danych o strukturze siatki, takich jak obrazy, w których co najmniej jedna warstwa zamiast zwykłego mnożenia macierzy wykonuje operację splotu [7]. Warstwa splotowa składa się z filtrów, czyli niewielkich macierzy wag, które są przesuwane po obrazie. W każdym położeniu filtr oblicza sumę iloczynów swoich wag i wartości pikseli, a wyniki dla wszystkich położeń tworzą mapę cech. Każde wyjście zależy więc tylko od małego fragmentu wejścia, a te same wagi są używane w całym obrazie [7, 6]. Dzięki temu sieć ma znacznie mniej parametrów niż sieć w pełni połączona, a cecha nauczona w jednym miejscu obrazu jest wykrywana również w każdym innym [7].

Typowa warstwa sieci splotowej składa się z trzech etapów: splotu, nieliniowej funkcji aktywacji, na przykład ReLU, oraz warstwy łączącej (ang. *pooling*), która zastępuje wartości z niewielkiego obszaru jedną liczbą, na przykład ich maksimum [7]. Warstwa łącząca zmniejsza rozmiar map cech [3] i sprawia, że wynik w niewielkim stopniu zależy od małych przesunięć obrazu [7]. Cała sieć składa się zwykle z kilku takich bloków, po których następują warstwy w pełni połączone [3]. Wagi sieci są dobierane metodą spadku gradientu, z gradientem obliczanym przez propagację wsteczną na kolejnych porcjach danych treningowych [3].

Kolejne warstwy sieci splotowej uczą się coraz bardziej złożonych cech: od prostych cech niskiego poziomu w pierwszych warstwach do bardziej ogólnych reprezentacji w warstwach dalszych [8]. W przypadku podpisów sieć splotowa, podobnie jak ręcznie projektowane metody, wyznacza cechy lokalnie, w nakładających się fragmentach obrazu, ale sposób ich wyznaczania nie jest z góry ustalony, tylko uczony z danych [6]. Duże sieci uczone na niewielkich zbiorach danych łatwo jednak dopasowują się do danych treningowych zamiast uczyć się ogólnych zależności, co nazywa się przeuczeniem [9]. Metody ograniczania przeuczenia użyte w pracy, takie jak porzucanie, normalizacja wsadowa i augmentacja danych, opisano w rozdziale 4.

2.5. Sieci syjamskie i funkcja straty kontrastowej

Sieć syjamska

Sieć syjamską zaproponowano w pracy [2] właśnie do weryfikacji podpisu [10]. Składała się ona z dwóch jednakowych podsieci, które wyznaczały cechy dwóch podpisów, oraz neuronu

wyjściowego mierzącego odległość między otrzymanymi wektorami cech [2]. Obie podsieci miały identyczne wagi, a jako miarę odległości użyto cosinusa kąta między wektorami. Podpisy pochodziły z tabletu, więc była to weryfikacja dynamiczna. Sieć trenowano na parach podpisów: w połowie były to pary dwóch podpisów prawdziwych, w 40% pary z fałszerstwem, a w 10% pary z fałszerstwem losowym, którego rolę pełnił prawdziwy podpis innej osoby [2]. Podczas weryfikacji wektor cech podpisu porównywano z zapisanym modelem podpisu danej osoby i akceptowano podpisy, których odległość była mniejsza od progu. Przy progu wykrywającym 80% fałszerstw system akceptował 95,5% podpisów prawdziwych [2].

W ogólnym ujęciu sieć syjamska składa się z trzech części: wyznaczania cech przez dwie gałęzie o tej samej budowie i tych samych wagach, porównania otrzymanych cech oraz podjęcia decyzji, na przykład przez porównanie z progiem [10]. Odmianą jest sieć pseudosyjamska, w której gałęzie nie mają wspólnych wag, stosowana na przykład dla danych różnego rodzaju [10]. Zaproponowano też sieci z większą liczbą gałęzi, na przykład sieć trójkową (ang. *triplet network*), która porównuje próbkę wzorcową jednocześnie z próbką tej samej klasy i próbką innej klasy [10]. Sieć syjamska uczy się przez porównywanie próbek, dlatego dobrze sprawdza się przy małej liczbie danych: z N próbek można utworzyć $N(N-1)/2$ par [10]. Dla 24 podpisów jednej osoby ze zbioru CEDAR daje to 276 par podpisów prawdziwych.

Funkcja straty kontrastowej

Do trenowania sieci syjamskich często używa się funkcji straty kontrastowej, opisanej w pracy [8]. Strata jest obliczana dla par próbek: dla par podobnych rośnie wraz z odległością między ich wektorami cech, a dla par niepodobnych jest dodatnia tylko wtedy, gdy odległość jest mniejsza od ustalonego marginesu. Sieć uczy się więc przyciągać do siebie wektory próbek podobnych i odpychać wektory próbek niepodobnych, ale nie dalej niż na odległość marginesu [8]. Składnik dla par niepodobnych jest niezbędny, ponieważ bez niego najmniejszą stratę dałoby przypisanie wszystkim próbkom tego samego wektora [8]. Nauczone odwzorowanie można stosować także do nowych próbek, których nie było w zbiorze treningowym [8]. Wzór funkcji straty w postaci użytej w niniejszej pracy podano w podrozdziale 4.3. Wyniki sieci syjamskich są wrażliwe na wartość marginesu, którą zwykle dobiera się na podstawie doświadczenia [10].

Sieć SigNet

Najbliższą niniejszej pracy jest sieć SigNet [3], czyli splotowa sieć syjamska do niezależnej od autora weryfikacji podpisów statycznych. Obrazy podpisów skalowano w niej do rozmiaru 155 $\times$ 220 pikseli bez zachowania proporcji, odwracano jasność i dzielono przez odchylenie standardowe wartości pikseli w zbiorze. Każda gałąź sieci miała cztery warstwy splotowe z filtrami od 11 $\times$ 11 do 3 $\times$ 3 oraz dwie warstwy w pełni połączone, z których ostatnia zwracała wektor cech o długości 128. Sieć trenowano funkcją straty kontrastowej z marginesem równym 1 i odległością euklidesową, algorytmem RMSprop przez 20 epok [3]. Na zbiorze CEDAR do treningu użyto 50 osób, a do testu 5, a dla każdej osoby wylosowano tyle samo par pozytywnych i negatywnych. Jako wynik podawano największą dokładność spośród wszystkich progów sprawdzonych na zbiorze testowym. Na zbiorze CEDAR uzyskano w ten sposób dokładność 100% [3].

W tej samej pracy sprawdzono również, jak sieć działa na innym zbiorze niż ten, na którym ją trenowano. Model wytrenowany na zbiorze CEDAR osiągał na pozostałych zbiorach dokładność od około 54% do 64%, co wskazuje, że każdy zbiór ma pewne charakterystyczne cechy [3]. Na zbiorze GPDS300 sprawdzono też trening bez fałszerstw wykwalifikowanych, w którym ich rolę pełniły podpisy prawdziwe innych osób, co obniżyło dokładność z 76,83% do 65,36% [3].

2.6. Uczenie na skróty

Głębokie sieci neuronowe często osiągają bardzo dobre wyniki na zbiorze testowym, mimo że nie nauczyły się zamierzonego zadania. Zjawisko to nazwano uczeniem na skróty (ang. *shortcut learning*), a skrót zdefiniowano jako regułę decyzyjną, która działa dobrze na standardowych zbiorach testowych, ale zawodzi w trudniejszych warunkach, na przykład w rzeczywistym zastosowaniu [11]. Przykładem jest sieć rozpoznająca krowy, która myliła się, gdy krowa stała w nietypowym otoczeniu, ponieważ zamiast zwierzęcia rozpoznawała trawę w tle. Innym przykładem jest sieć wykrywająca zapalenie płuc na zdjęciach rentgenowskich, która zamiast płuc rozpoznawała znacznik charakterystyczny dla szpitala, w którym wykonano zdjęcie, i zawodziła na zdjęciach z nowych szpitali [11].

Skróty biorą się z systematycznych zależności w danych, na przykład między obiektem a tłem, nazywanych obciążeniem zbioru danych (ang. *dataset bias*) [11]. Sieć wykorzystuje dowolną cechę, która wystarcza do rozróżnienia klas w danym zbiorze, a na to, której cechy się nauczy, wpływają także budowa sieci, funkcja straty i sposób optymalizacji [11].

Ponieważ zbiór testowy zwykle pochodzi z tego samego źródła co treningowy, skrót daje dobre wyniki również na teście i łatwo go przeoczyć. Autorzy pracy [11] zalecają ostrożną interpretację wyników oraz sprawdzanie, czy prosta metoda, która nie korzysta z zamierzonych cech, nie osiąga zaskakująco dobrego wyniku.

W zbiorach podpisów podpisy prawdziwe i fałszerstwa zbiera się w różny sposób: osoby składają swoje podpisy w jednej lub kilku sesjach, a fałszerstwa powstają w osobnym procesie, w którym inne osoby naśladują pokazane im podpisy [1]. Różnice wynikające ze sposobu zbierania danych, na przykład w rodzaju długopisu czy warunkach skanowania, mogą więc stać się dla sieci skrótem pozwalającym odróżnić fałszerstwa bez analizy kształtu podpisu. Takie różnice znaleziono w zbiorze CEDAR w ramach niniejszej pracy, a ich wpływ na wyniki zbadano w rozdziale 5.

3. Zbiór danych i jego przygotowanie

3.1. Zbiór CEDAR

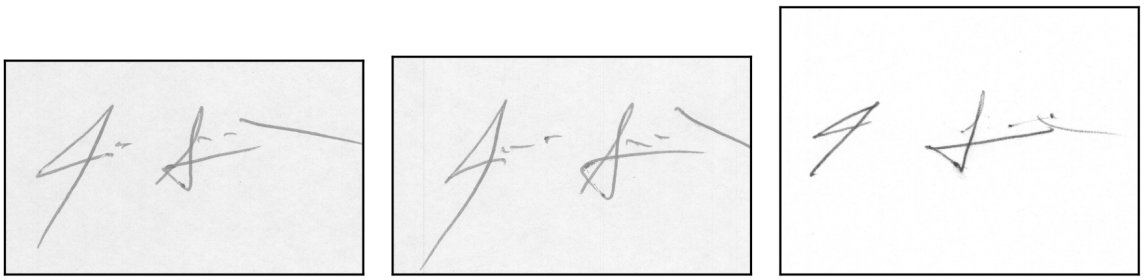
Do trenowania i testowania modelu wykorzystano zbiór podpisów CEDAR, przygotowany w ośrodku Center of Excellence for Document Analysis and Recognition Uniwersytetu w Buffalo. Zbiór zawiera podpisy 55 osób, z których każda złożyła 24 podpisy prawdziwe w wyznaczonym polu o wymiarach 2×2 cale. Fałszerstwa przygotowało około 20 innych osób, które miały jak najdokładniej podrobić podpisy osób ze zbioru, dzięki czemu dla każdej osoby zebrano 24 fałszerstwa wykwalifikowane. Podpisy zeskanowano z rozdzielczością 300 dpi w 8-bitowej skali szarości i zapisano w formacie PNG [5]. Podstawowe parametry zbioru zestawiono w tabeli 3.1.

Tabela 3.1. Podstawowe parametry zbioru CEDAR

Parametr	Wartość
liczba osób	55
podpisy prawdziwe na osobę	24
fałszerstwa wykwalifikowane na osobę	24
podpisy prawdziwe łącznie	1320
fałszerstwa łącznie	1320
wszystkie obrazy	2640

Zbiór CEDAR jest często wykorzystywany w pracach dotyczących weryfikacji podpisu, między innymi w [3, 6], dzięki czemu wyniki uzyskane w niniejszej pracy można porównać z wynikami innych autorów.

W pracy użyto kopii zbioru udostępnionej w serwisie Kaggle [12]. Obrazy podzielone są na dwa katalogi: `full_org` z podpisami prawdziwymi oraz `full_forg` z fałszerstwami. Nazwa pliku zawiera numer osoby i numer podpisu, na przykład `original_1_5.png` to piąty prawdziwy podpis osoby nr 1, a `forgeries_1_5.png` to piąte fałszerstwo jej podpisu. Według autorów zbioru wszystkie obrazy zapisano w skali szarości, jednak w użytej kopii część plików ma inne tryby kolorów, co opisano w podrozdziale 3.2. Na rys. 3.1 przedstawiono przykładowe podpisy jednej osoby ze zbioru.



a) podpis prawdziwy b) podpis prawdziwy c) fałszerstwo

Rys. 3.1. Przykładowe podpisy jednej osoby ze zbioru CEDAR: dwa podpisy prawdziwe (a, b) i fałszerstwo wykwalifikowane (c)

3.2. Analiza eksploracyjna danych

Przed przygotowaniem danych do treningu przeprowadzono analizę zbioru, aby sprawdzić jego poprawność i wykryć cechy obrazów, które mogłyby utrudnić trening sieci albo zafałszować wyniki. Analizę wykonano w języku Python z użyciem bibliotek Pillow i NumPy.

Najpierw sprawdzono kompletność zbioru. W katalogu `full_org` znajduje się 1320 obrazów i tyle samo w katalogu `full_forg`, po 24 dla każdej z 55 osób. Dla każdego pliku obliczono skrót MD5 (ang. *Message Digest 5* – algorytm obliczania skrótu), co pozwoliło stwierdzić, że w zbiorze nie ma powtórzonych obrazów. Sprawdzono także, czy wszystkie pliki dają się poprawnie otworzyć, i żaden nie okazał się uszkodzony. Oprócz obrazów w katalogach znajdują się jedynie pliki systemowe `Thumbs.db`, które pominięto.

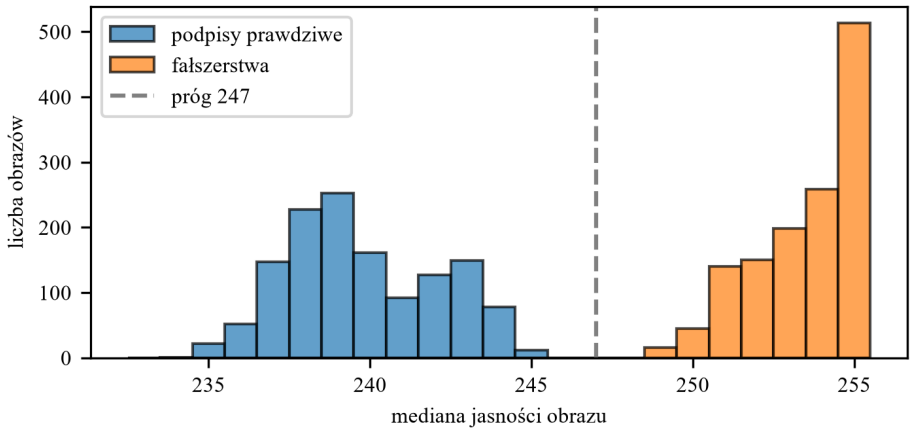
Następnie sprawdzono tryby kolorów obrazów. Według autorów zbioru wszystkie podpisy zapisano w 8-bitowej skali szarości [5], jednak w użytej kopii podpisy prawdziwe zapisane są w trybach RGBA (ang. *red, green, blue, alpha* – trzy kanały koloru i kanał przezroczystości) i L (skala szarości), a fałszerstwa w trybach P (paleta kolorów) i RGBA. Kolor nie niesie informacji o kształcie podpisu, dlatego wszystkie obrazy przy wczytywaniu zamieniane są na skalę szarości.

Obrazy w zbiorze nie mają wspólnego rozmiaru. Wśród 1320 podpisów prawdziwych występuje 1095 różnych rozmiarów, a wśród fałszerstw 1006. Mediana rozmiaru wynosi 577 $\times$ 349 pikseli dla podpisów prawdziwych i 576 $\times$ 336 pikseli dla fałszerstw (szerokość $\times$ wysokość), a szerokość obrazów waha się od 264 do 888 pikseli. Sieć wymaga obrazów o jednakowym rozmiarze, dlatego wszystkie obrazy trzeba przeskalować. Ponieważ podpisy są wyraźnie szersze niż wyższe (proporcja około 1,7:1), wejście sieci powinno mieć kształt prostokąta, a nie kwadratu. Okazało się również, że rozmiar obrazu niemal jedno-

znacznie wskazuje osobę, do której należy podpis: 85,4% rozmiarów występujących wśród podpisów prawdziwych i 78,1% wśród fałszerstw pojawia się tylko u jednej osoby. Gdyby obrazy nie zostały ujednolicone, sieć mogłaby nauczyć się rozpoznawać osobę po rozmiarze obrazu, a nie po kształcie podpisu.

Prostokąt obejmujący podpis zajmuje średnio około 60% powierzchni obrazu (60,1% dla podpisów prawdziwych i 58,6% dla fałszerstw), a resztę stanowi puste tło. Za piksele podpisu uznano piksele o jasności mniejszej niż 200. Przy przeskalowaniu całego obrazu do niewielkiego wejścia sieci znaczna jego część przypadałaby więc na tło. Z tego powodu rozważono przycinanie obrazów do prostokąta zawierającego podpis, a wybór sposobu przygotowania obrazu opisano w podrozdziale 4.1.

Najważniejszym wynikiem analizy okazała się różnica w jasności tła między podpisami prawdziwymi a fałszerstwami. Dla każdego obrazu obliczono medianę jasności pikseli, która, ponieważ podpis zajmuje tylko niewielką część pikseli, odpowiada w przybliżeniu jasności tła. Rozkład tej wartości przedstawiono na rys. 3.2.



Rys. 3.2. Rozkład mediany jasności obrazów dla podpisów prawdziwych i fałszerstw w zbiorze CEDAR

Dla podpisów prawdziwych mediana mieści się w przedziale od 234 do 245 (średnio 239,8), a dla fałszerstw od 249 do 255 (średnio 253,5), przy czym 513 z 1320 fałszerstw ma tło idealnie białe. Przedziały te nie nakładają się, więc pojedynczy próg jasności równy 247 pozwala bezbłędnie oddzielić wszystkie podpisy prawdziwe od fałszerstw bez analizowania samego podpisu. Sieć trenowana na takich danych mogłaby wykorzystać tę różnicę zamiast uczyć się cech podpisu, co zawyżyłoby wyniki dla fałszerstw wykwalifikowanych. Na podstawie dostępnych informacji nie da się ustalić, czy różnica ta pochodzi z oryginalnego skanowania, czy z późniejszej konwersji plików. Sposób jej usunięcia opisano w rozdziale 4.

Na koniec sprawdzono, czy do odróżniania podpisów wystarczy proste porównanie obrazów. Obrazy przeskalowano do rozmiaru 128 $\times$ 128 pikseli i dla wszystkich par opisanych w podrozdziale 3.4 obliczono współczynnik korelacji Pearsona między wartościami pikseli. Średnia korelacja wyniosła 0,158 (odchylenie standardowe 0,090) dla par dwóch podpisów prawdziwych tej samej osoby, 0,104 (0,069) dla par z fałszerstwem wykwalifikowanym oraz 0,083 (0,061) dla par podpisów dwóch różnych osób. Rozkłady te w dużym stopniu się nakładają. Korelację potraktowano jako miarę podobieństwa i wybrano próg, przy którym odsetek błędnie odrzuconych par prawdziwych jest równy odsetkowi błędnie zaakceptowanych par fałszywych. Błąd w tym punkcie, nazywany równym współczynnikiem błędów (ang. *equal error rate*, EER), wyniósł 38,0% dla fałszerstw wykwalifikowanych i 32,3% dla fałszerstw losowych. Prosta metoda myli się więc w około jednej trzeciej przypadków, co uzasadnia zastosowanie sieci neuronowej. Wynik ten posłuży również jako punkt odniesienia przy ocenie sieci w rozdziale 5.

3.3. Podział na zbiory niezależne od autora

W niniejszej pracy zastosowano podejście niezależne od autora, opisane w podrozdziale 2.1, w którym do treningu i testu używa się rozłącznych grup osób. Osoby ze zbioru CEDAR podzielono losowo na trzy rozłączne grupy: 35 osób do zbioru treningowego, 10 do walidacyjnego i 10 do testowego. Liczbę podpisów w każdym ze zbiorów przedstawiono w tabeli 3.2.

Tabela 3.2. Podział zbioru CEDAR na zbiory treningowy, walidacyjny i testowy

Zbiór	Liczba osób	Podpisy prawdziwe	Fałszerstwa
treningowy	35	840	840
walidacyjny	10	240	240
testowy	10	240	240
razem	55	1320	1320

Zbiór treningowy służy do uczenia sieci, zbiór walidacyjny do wyboru progu decyzyjnego i porównywania wariantów modelu, a zbiór testowy wyłącznie do końcowej oceny. Żadna osoba nie występuje w więcej niż jednym zbiorze, więc wynik na zbiorze testowym pokazuje, jak model radzi sobie z podpisami osób, których wcześniej nie widział. Losowanie wykonano z ustalonym ziarnem generatora liczb losowych (ang. *seed*), a wynik podziału zapisano w pliku, dzięki czemu podział jest za każdym razem taki sam i wszystkie eksperymenty korzystają z tych samych grup osób. Ostateczną skuteczność modelu oceniono

dodatkowo walidacją krzyżową, w której każda osoba raz należy do zbioru testowego (podrozdział 5.4).

W literaturze stosowane są różne sposoby podziału zbioru CEDAR. Na przykład w pracy [3] do treningu użyto 50 osób, a do testu 5. Z kolei w pracy [5] podzielono podpisy, a nie osoby: 16 podpisów każdej osoby użyto do treningu, a 8 do testu, więc te same osoby występowały w obu zbiorach. Wyniki uzyskane przy różnych sposobach podziału nie są więc bezpośrednio porównywalne, co uwzględniono przy analizie wyników w rozdziale 5.

3.4. Budowa par podpisów

Sieć syjamska uczy się na parach podpisów, z których każda jest oznaczona jako para pozytywna (oba podpisy prawdziwe i należące do tej samej osoby) albo para negatywna. Pary zbudowano osobno w każdym ze zbiorów opisanych w podrozdziale 3.3, tak aby oba podpisy w parze zawsze pochodziły od osób z tego samego zbioru. Wykorzystano trzy rodzaje par.

Pary pozytywne utworzono z podpisów prawdziwych jednej osoby. Z 24 podpisów można utworzyć 276 różnych par, z których dla każdej osoby wylosowano 48. Pary negatywne z fałszerstwami wykwalifikowanymi utworzono, łącząc podpis prawdziwy osoby z fałszerstwem jej podpisu. Spośród 576 możliwych połączeń (24×24) dla każdej osoby wylosowano 24 pary. Pary negatywne z fałszerstwami losowymi utworzono, łącząc każdy z 24 podpisów prawdziwych osoby z losowo wybranym podpisem prawdziwym innej osoby z tego samego zbioru. Taki sposób symulowania fałszerstw losowych, w którym rolę fałszerstwa pełni prawdziwy podpis innej osoby, zastosowano już w pracy, w której zaproponowano sieci syjamskie [2]. W pracy nie uwzględniono fałszerstw prostych, w których fałszerz zna imię i nazwisko osoby, ale nie zna jej podpisu [1], ponieważ zbiór CEDAR ich nie zawiera.

Dla każdej osoby powstało więc 48 par pozytywnych i 48 par negatywnych (24 z fałszerstwami wykwalifikowanymi i 24 z fałszerstwami losowymi), dzięki czemu obie klasy są równoliczne i sieć nie faworyzuje żadnej z nich. Liczbę par w poszczególnych zbiorach przedstawiono w tabeli 3.3.

Pary zapisano w plikach CSV (ang. *comma-separated values* – wartości rozdzielone przecinkami), w których dla każdej pary podano nazwy obu plików, numery osób, rodzaj pary oraz zbiór, do którego należy. Losowanie wykonano z ustalonymi ziarnami generatora liczb losowych, dzięki czemu pary można odtworzyć. Po zapisaniu pliki sprawdzono automatycznie: dla każdej pary porównano numer osoby odczytany z nazwy pliku z numerem

Tabela 3.3. Liczba par podpisów w zbiorach treningowym, walidacyjnym i testowym

Zbiór	Pozytywne	Wykwalifikowane	Losowe	Razem
treningowy	1680	840	840	3360
walidacyjny	480	240	240	960
testowy	480	240	240	960
razem	2640	1320	1320	5280

zapisanym w pliku CSV, sprawdzono, czy oba podpisy należą do właściwego zbioru, oraz czy rodzaj pary jest zgodny z osobami, od których pochodzą podpisy. Sprawdzenie nie wykazało żadnych błędów.

4. Model sieci syjamskiej

W rozdziale opisano kolejne elementy proponowanego rozwiązania: przygotowanie obrazów przed podaniem ich do sieci, budowę sieci syjamskiej, funkcję straty oraz sposób treningu.

4.1. Przygotowanie obrazów

Analiza opisana w podrozdziale 3.2 pokazała, że obrazy w zbiorze CEDAR różnią się rozmiarem i trybem kolorów, a podpisy prawdziwe i fałszerstwa różnią się jasnością tła. Przed podaniem do sieci każdy obraz przechodzi więc przez te same kroki, wykonywane w podanej kolejności:

1) zamiana na skalę szarości,
2) usunięcie tła metodą Otsu,
3) wyrównanie ciemności atramentu,
4) dopasowanie do rozmiaru wejścia sieci bez zniekształcania proporcji,
5) odwrócenie jasności i przeskalowanie wartości do przedziału od 0 do 1.

Wszystkie kroki zaimplementowano w języku Python z użyciem bibliotek OpenCV i NumPy. Kolejne kroki dla przykładowego podpisu prawdziwego i fałszerstwa przedstawiono na rys. 4.1.

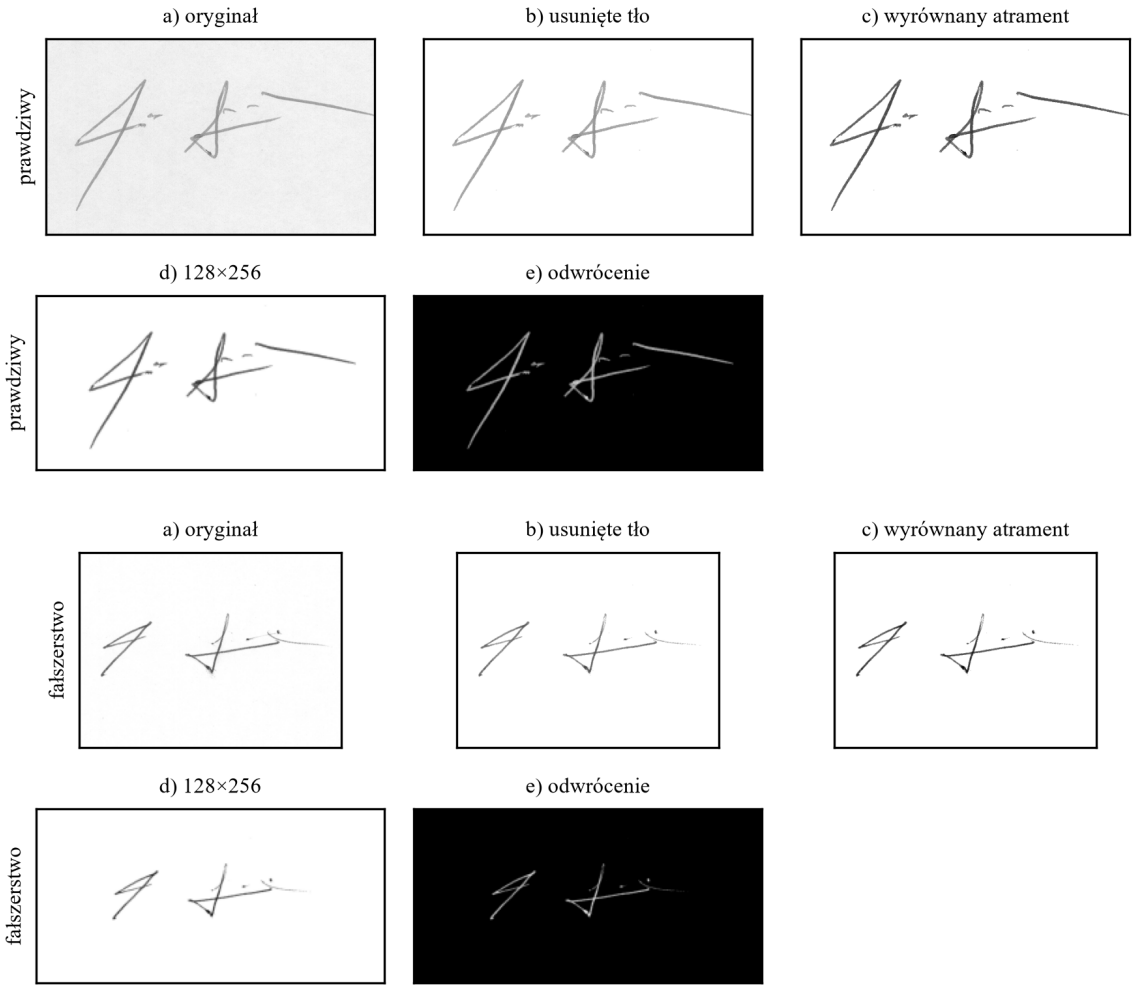
Usunięcie tła

Do oddzielenia podpisu od tła użyto metody Otsu [13], która automatycznie wyznacza próg jasności na podstawie histogramu obrazu. Metoda dzieli piksele progiem k na dwie grupy: piksele ciemniejsze od progu (podpis) i piksele jaśniejsze (tło). Dla każdego możliwego progu obliczana jest wariancja międzyklasowa

$$\sigma_B^2(k) = \omega_0(k)\,\omega_1(k)\,\big(\mu_1(k) - \mu_0(k)\big)^2, \tag{4.1}$$

gdzie ω_0 i ω_1 oznaczają udział pikseli w każdej z grup, a μ_0 i μ_1 ich średnią jasność. Wybierany jest próg, dla którego wartość σ_B^2 jest największa, czyli taki, przy którym obie grupy najbardziej różnią się jasnością [13].

Piksele jaśniejsze od wyznaczonego progu otrzymują wartość 255 (kolor biały), a piksele podpisu zachowują swoją jasność, tak jak w pracy [6]. Obraz nie jest więc binaryzowany, a sieć dostaje informację o odcieniach kresek. Wyznaczone progi wynosiły od 170 do 210 dla podpisów prawdziwych i od 174 do 226 dla fałszerstw. Po tym



Rys. 4.1. Kolejne kroki przygotowania obrazu dla podpisu prawdziwego (dwa górne wiersze) i fałszerstwa wykwalifikowanego (dwa dolne wiersze) osoby nr 1: a) oryginał, b) po usunięciu tła, c) po wyrównaniu atramentu, d) po dopasowaniu do rozmiaru 128 $\times$ 256, e) po odwróceniu jasności

kroku mediana jasności każdego z 2640 obrazów wynosi 255, więc różnica jasności tła opisana w podrozdziale 3.2 zostaje usunięta. Wpływ tego kroku na wyniki sieci zbadano w rozdziale 5.

Wybór obszaru obrazu

Rozważono trzy sposoby wyboru obszaru obrazu, który jest następnie dopasowywany do wejścia sieci. W pierwszym obraz jest przycinany do najmniejszego prostokąta zawierającego wszystkie piksele podpisu, czyli piksele o jasności mniejszej niż 255 po usunięciu tła. Podpis zajmuje wtedy możliwie dużą część wejścia sieci, ale każdy podpis jest skalowany inaczej, więc informacja o jego rozmiarze zostaje utracona. W drugim do wejścia sieci dopasowywany jest cały obraz po usunięciu tła, podobnie jak w pracy [3]. W trzecim podpis jest umieszczany na białym tle o rozmiarze 730 $\times$ 1460 pikseli, większym niż największy pod-

pis w zbiorze, tak aby jego środek masy znalazł się w środku tła, jak w pracy [6]. Wszystkie podpisy są wtedy skalowane w tej samej skali, ale na wejściu sieci zajmują niewielką część obrazu.

Warianty porównano doświadczalnie, a wyniki przedstawiono w rozdziale 5. Najmniejszy błąd na zbiorze walidacyjnym uzyskano dla całego obrazu, dlatego ten wariant przyjęto jako podstawowy.

Wyrównanie ciemności atramentu

Po usunięciu tła okazało się, że podpisy prawdziwe i fałszerstwa różnią się także ciemnością kresek. Podpisy jednej osoby zbierano w jednej sesji tym samym długopisem, a fałszerstwa powstawały w innych warunkach. Mediana różnicy ciemności atramentu wynosiła 3 dla par dwóch podpisów prawdziwych tej samej osoby i 18 dla par z fałszerstwem. Porównanie samej ciemności atramentu, bez analizy kształtu podpisu, dawało dla fałszerstw wykwalifikowanych EER równy 21,1%.

Aby ograniczyć tę różnicę, jasność pikseli podpisu jest przeskalowywana tak, aby mediana ich ciemności (różnicy między 255 a jasnością piksela) była taka sama w każdym obrazie. Po przeskalowaniu mediana jasności pikseli podpisu wynosi 100. Kształt kresek i różnice odcieni w obrębie podpisu zostają zachowane. Po tej zmianie EER uzyskany na podstawie samej ciemności atramentu wzrósł do 36,7%. Różnica nie zniknęła całkowicie, co prawdopodobnie wynika z różnej grubości kresek przy użyciu innego długopisu.

Dopasowanie do rozmiaru wejścia

Jako rozmiar wejścia sieci przyjęto 128 $\times$ 256 pikseli (wysokość $\times$ szerokość). Obraz jest zmniejszany lub powiększany z zachowaniem proporcji tak, aby zmieścił się w tym prostokącie, a wolne miejsce jest dopełniane białym tłem. Obraz znajduje się w środku wejścia sieci. Proporcji nie zmieniano, ponieważ rozciągnięcie obrazu zmieniłoby kształt liter, inaczej niż w pracy [3], w której wszystkie obrazy skalowano do jednego rozmiaru bez zachowania proporcji. Przy zmniejszaniu użyto interpolacji `INTER_AREA`, która uśrednia piksele i nie gubi cienkich kresek.

Proporcję 1:2 dobrano na początku prac do obrazów przyciętych do podpisu, dla których mediana stosunku szerokości do wysokości wynosiła około 2,1. Rozmiar wejścia wybrano na podstawie porównania czterech wariantów: 64 $\times$ 128, 128 $\times$ 216, 128 $\times$ 256 i 256 $\times$ 512 pikseli, opisanego w rozdziale 5. Wariant 128 $\times$ 216 ma proporcję około 1,7, taką jak całe obrazy (podrozdział 3.2), więc nie powstają w nim białe pasy po bokach, jed-

nak nie dał on poprawy. Mniejsze wejście 64×128 dało większy błąd na zbiorze walidacyjnym. Wejście 256×512 dało mniejszy błąd na zbiorze walidacyjnym, ale nie na zbiorze testowym, a jeden trening trwał ponad osiem razy dłużej, dlatego pozostano przy rozmiarze 128×256.

Odwrócenie jasności

Na koniec jasność każdego piksela p jest zamieniana na wartość $1 - p/255$. Tło ma wtedy wartość 0, a piksele podpisu wartości bliskie 1, tak jak w pracach [3, 6]. Taka postać jest wygodna dla sieci, ponieważ puste miejsca obrazu mają wartość zero, tak samo jak dopełnienie stosowane przy obrotach i przesunięciach obrazu w czasie augmentacji danych (podrozdział 4.3).

Wpływ przygotowania obrazów na metodę porównawczą

Prosta metoda porównawcza z podrozdziału 3.2 została powtórzona na obrazach przygotowanych w opisany sposób. EER wyniósł 38,0% dla fałszerstw wykwalifikowanych i 32,0% dla fałszerstw losowych, czyli prawie tyle samo co dla obrazów nieprzetworzonych (38,0% i 32,3%). Przygotowanie obrazów nie ułatwia więc zadania prostej metodzie, która nadal myli się w około jednej trzeciej przypadków. Gdy obrazy dodatkowo przycinano do prostokąta zawierającego podpis, EER dla fałszerstw wykwalifikowanych wzrastał do 42,1%. Wskazuje to, że przycinanie usuwa część informacji przydatnej do wykrywania fałszerstw, co omówiono w podrozdziale 5.2.

4.2. Budowa sieci syjamskiej

Sieć syjamska składa się z dwóch jednakowych gałęzi, które mają wspólne wagi [2]. Każda gałąź zamienia obraz podpisu na wektor liczb, nazywany wektorem cech, a następnie obliczana jest odległość między wektorami obu podpisów. Dzięki wspólnym wagom oba podpisy są przetwarzane w dokładnie ten sam sposób, a w implementacji wystarczy jedna sieć, przez którą kolejno przechodzą oba obrazy pary.

Gałąź sieci jest splotową siecią neuronową (ang. *convolutional neural network*, CNN) złożoną z czterech bloków. Każdy blok zawiera warstwę splotową, normalizację wsadową (ang. *batch normalization*) [14], funkcję aktywacji ReLU (ang. *rectified linear unit* – funkcja zwracająca wartość wejścia dla wartości dodatnich i zero dla ujemnych) oraz warstwę łączącą (ang. *max pooling*), która zmniejsza wysokość i szerokość mapy cech dwukrotnie. Pierwsza warstwa splotowa ma filtry o rozmiarze 5×5, a pozostałe 3×3. Po czterech blo-

kach mapy cech są uśredniane do siatki 2×4, a otrzymane 1024 wartości przechodzą przez warstwę porzucania (ang. *dropout*) [15] i warstwę w pełni połączoną, która zwraca wektor cech o długości 128. Wektor jest na końcu normalizowany do długości 1, dzięki czemu odległość między dwoma wektorami zawsze mieści się w przedziale od 0 do 2. Budowę jednej gałęzi przedstawiono w tabeli 4.1.

Tabela 4.1. Budowa jednej gałęzi sieci syjamskiej dla wejścia o rozmiarze 128×256

Warstwa	Parametry	Rozmiar wyjścia	Liczba wag
wejście	–	$1 \times 128 \times 256$	–
blok 1	splot 5×5, 32 filtry	$32 \times 64 \times 128$	896
blok 2	splot 3×3, 64 filtry	$64 \times 32 \times 64$	18 624
blok 3	splot 3×3, 128 filtrów	$128 \times 16 \times 32$	74 112
blok 4	splot 3×3, 128 filtrów	$128 \times 8 \times 16$	147 840
uśrednianie	siatka 2×4	1024	–
porzucanie	$p = 0{,}3$	1024	–
w pełni połączona	$1024 \to 128$	128	131 200
normalizacja	długość wektora 1	128	–
razem			372 672

Uśrednianie do stałej siatki 2×4 sprawia, że liczba wartości przekazywanych do warstwy w pełni połączonej nie zależy od rozmiaru obrazu wejściowego. Tę samą sieć można więc stosować bez zmian dla różnych rozmiarów wejścia, co wykorzystano w rozdziale 5. Normalizacja wsadowa w czasie treningu korzysta ze średniej i wariancji obliczonych na bieżącej porcji danych, a w czasie oceny z wartości uśrednionych podczas całego treningu [14]. Warstwa porzucania w czasie treningu losowo wyłącza 30% wartości, co utrudnia sieci zapamiętanie danych treningowych, a w czasie oceny jest nieaktywna [15].

Dla pary obrazów x_1 i x_2 sieć zwraca odległość euklidesową między ich wektorami cech

$$D = \|f(x_1) - f(x_2)\|_2, \tag{4.2}$$

gdzie f oznacza gałąź sieci. Mała odległość oznacza, że podpisy są podobne, a duża, że się różnią.

4.3. Funkcja straty i trening

Funkcja straty

Sieć trenowano funkcją straty kontrastowej (ang. *contrastive loss*) [8]. Dla pary o etykiecie y ($y = 1$ dla dwóch podpisów tej samej osoby i $y = 0$ dla pary negatywnej) i odległości D ze

wzoru (4.2) strata wynosi

$$L = yD^2 + (1-y)\left(\max(0, m-D)\right)^2, \tag{4.3}$$

gdzie m jest marginesem. Dla par pozytywnych strata rośnie wraz z odległością, więc sieć uczy się zbliżać do siebie wektory podpisów tej samej osoby. Dla par negatywnych strata jest dodatnia tylko wtedy, gdy odległość jest mniejsza od marginesu, więc sieć oddala od siebie wektory różnych podpisów, ale nie dalej niż na odległość m. Bez składnika dla par negatywnych sieć mogłaby przypisać wszystkim obrazom ten sam wektor i uzyskać zerową stratę [8]. Przyjęto margines $m = 1$, tak jak w pracy [3]. W porównaniu z pracą [8] zamieniono oznaczenie etykiet i pominięto czynnik $\frac{1}{2}$ przed oboma składnikami, co nie zmienia położenia minimum funkcji straty.

Przebieg treningu

Do optymalizacji wag użyto algorytmu Adam [16] z krokiem uczenia 0,001, czyli wartością zalecaną przez autorów metody, oraz z karą za duże wartości wag (ang. *weight decay*) równą 10^{-4}. Sieć trenowano w porcjach po 32 pary. W eksperymentach porównujących warianty modelu trening trwał 30 epok, a model końcowy trenowano przez 50 epok, co uzasadniono w podrozdziale 5.4. Na początku każdej epoki losowano nowe pary treningowe: dla każdej osoby 48 par pozytywnych, 24 pary z fałszerstwem wykwalifikowanym i 24 pary losowe, w taki sam sposób jak w podrozdziale 3.4. Dzięki temu w kolejnych epokach sieć widzi różne połączenia podpisów, a klasy pozostają równoliczne. Pary walidacyjne i testowe były stałe.

W czasie treningu stosowano augmentację danych, czyli niewielkie losowe zmiany obrazów, które zwiększają różnorodność danych treningowych [9]. Każdy obraz pary był niezależnie obracany o kąt do $\pm 5^\circ$, przesuwany o maksymalnie 5% szerokości i wysokości oraz zmniejszany do 85–100% rozmiaru, a puste miejsca wypełniano wartością tła. Zastosowano tylko małe kąty obrotu, ponieważ duże obroty mogą zmienić znaczenie obrazu [9]. Nie stosowano powiększania, które ucinało końce podpisów, ani pocieniania kresek, po którym znikały cienkie linie. Augmentację stosowano wyłącznie do zbioru treningowego.

Wybór modelu i progu

Po każdej epoce obliczano EER na wszystkich parach zbioru walidacyjnego i zapisywano model z epoki o najmniejszym błędzie. Próg decyzyjny wyznaczano na zbiorze walidacyjnym, na parach pozytywnych i parach z fałszerstwami wykwalifikowanymi, w punkcie

równego współczynnika błędów. Zbiór testowy wykorzystywano tylko do końcowej oceny wybranego modelu.

Każdy wariant trenowano trzykrotnie, z różnymi ziarnami generatora liczb losowych, które decydują o początkowych wagach sieci, losowaniu par i augmentacji. Wyniki podawane są jako średnia i odchylenie standardowe z trzech treningów. Sprawdzono, że ponowny trening z tym samym ziarnem daje identyczny wynik. Sieć zaimplementowano w bibliotece PyTorch i trenowano na karcie graficznej NVIDIA GeForce RTX 4070 Laptop, a jeden trening przez 30 epok trwał około 9 minut.

5. Badania eksperymentalne i wyniki

W rozdziale przedstawiono wyniki badań przeprowadzonych z użyciem sieci opisanej w rozdziale 4. Najpierw opisano miary oceny i sposób prowadzenia badań. Następnie porównano warianty przygotowania danych i treningu oraz zbadano, jak na wynik wpływają różnice między podpisami prawdziwymi a fałszerstwami, które nie dotyczą kształtu podpisu. Na końcu przedstawiono ocenę końcowego modelu walidacją krzyżową oraz porównanie z wynikami innych autorów.

5.1. Miary oceny i przebieg badań

Miary oceny

Do oceny użyto miar opisanych w podrozdziale 2.2. Dla każdej pary podpisów sieć zwraca odległość D ze wzoru (4.2), a para jest uznawana za parę podpisów tej samej osoby, gdy odległość nie przekracza progu decyzyjnego t. Współczynniki FAR i FRR obliczano ze wzoru (2.1).

Główną miarą użytą w pracy jest równy współczynnik błędów EER. W implementacji sprawdzane są kolejno wszystkie progi równe odległościom występującym w danych, wybierany jest ten, dla którego różnica między FAR a FRR jest najmniejsza, a jako EER podawana jest średnia obu współczynników. EER nie zależy od wybranego wcześniej progu, dlatego nadaje się do porównywania wariantów modelu. Dodatkowo podawane są FAR i FRR przy progu wyznaczonym na zbiorze walidacyjnym (podrozdział 4.3), które pokazują, jak system działa, gdy próg trzeba ustalić przed oceną.

EER obliczano osobno dla fałszerstw wykwalifikowanych (pary pozytywne i pary z fałszerstwem wykwalifikowanym) oraz dla fałszerstw losowych (pary pozytywne i pary podpisów dwóch różnych osób). W obu przypadkach używane są te same pary pozytywne i ten sam próg, więc FRR przy progu z walidacji jest dla obu rodzajów fałszerstw taki sam.

Przebieg badań

Warianty modelu porównywano na podziale osób opisanym w podrozdziale 3.3, w którym zbiór testowy zawiera 480 par pozytywnych, 240 par z fałszerstwami wykwalifikowanymi i 240 par z fałszerstwami losowymi (tabela 3.3). W każdym eksperymencie zmieniano tylko jedną rzecz, a pozostałe ustawienia pozostawały takie, jak w najlepszym dotychczasowym wariancie. Sieć trenowano przez 30 epok, w sposób opisany w podrozdziale 4.3.

Każdy wariant trenowano trzykrotnie, z ziarnami generatora liczb losowych równymi 1, 2 i 3, a wyniki podano jako średnią i odchylenie standardowe z trzech treningów. Pojedynczy trening okazał się niewystarczający. W pierwszych sześciu treningach (dwa warianty, po trzy ziarna) EER dla fałszerstw wykwalifikowanych wynosił od 18,8% do 28,6%, a różnica między wariantami była mniejsza niż różnica między ziarnami. Wcześniejsze porównanie tych samych wariantów na podstawie jednego treningu wskazywało poprawę o 3,3 punktu procentowego, która po powtórzeniu okazała się przypadkowa.

Zbiór testowy zawiera tylko 10 osób, dlatego różnice między wariantami wynoszące 1–2 punkty procentowe nie są pewne. Z tego powodu końcową ocenę modelu przeprowadzono dodatkowo walidacją krzyżową, opisaną w podrozdziale 5.4.

5.2. Porównanie wariantów modelu

Eksperymenty opisano w kolejności, w jakiej je wykonywano. Na początku obrazy były przycinane do prostokąta zawierającego podpis, dlatego eksperymenty dotyczące par treningowych i augmentacji przeprowadzono z przycinaniem, a sposób wyboru obszaru obrazu porównano później. Wyniki wszystkich wariantów zestawiono w tabeli 5.1.

Tabela 5.1. Wyniki wariantów modelu na stałym podziale osób (EER w procentach, średnia $\pm$ odchylenie standardowe z trzech treningów; pierwsza grupa z przycinaniem do podpisu, trzecia z całym obrazem)

Wariant	Walidacja	Wykwalifikowane	Losowe
stałe pary, bez augmentacji	$18{,}8 \pm 1{,}6$	$23{,}7 \pm 3{,}8$	$16{,}5 \pm 2{,}8$
nowe pary w każdej epoce	$19{,}3 \pm 2{,}2$	$24{,}6 \pm 3{,}0$	$16{,}1 \pm 1{,}4$
augmentacja geometryczna	$14{,}2 \pm 0{,}8$	$20{,}3 \pm 1{,}9$	$11{,}1 \pm 0{,}6$
augmentacja z pogrubianiem kresek	$14{,}9 \pm 0{,}3$	$23{,}0 \pm 2{,}0$	$13{,}5 \pm 1{,}4$
cały obraz	$13{,}5 \pm 0{,}9$	$17{,}2 \pm 0{,}5$	$12{,}5 \pm 1{,}2$
środek masy na dużym tle	$18{,}7 \pm 0{,}7$	$26{,}2 \pm 0{,}7$	$17{,}3 \pm 3{,}1$
wejście 64×128	$16{,}9 \pm 1{,}1$	$16{,}9 \pm 1{,}9$	$13{,}7 \pm 1{,}3$
wejście 128×216	$14{,}1 \pm 0{,}4$	$16{,}6 \pm 1{,}8$	$15{,}2 \pm 1{,}3$
wejście 256×512	$11{,}7 \pm 0{,}6$	$19{,}2 \pm 1{,}8$	$12{,}9 \pm 1{,}6$

Losowanie nowych par w każdej epoce

W pierwszym wariancie sieć trenowano na stałych parach treningowych z tabeli 3.3. W drugim na początku każdej epoki losowano nowe pary, tak jak opisano w podrozdziale 4.3. Oba warianty trenowano bez augmentacji. Średni EER dla fałszerstw wykwalifikowanych wyniósł 23,7% dla stałych par i 24,6% dla nowych par, a dla fałszerstw losowych odpowiednio 16,5% i 16,1%. Różnice są mniejsze niż rozrzut między ziarnami, więc losowanie nowych par nie dało wyraźnej poprawy. Pozostawiono je, ponieważ nie pogarszało wyników, a po-

zwala wykorzystać w treningu wszystkie fałszerstwa i znacznie więcej połączeń podpisów prawdziwych niż stały zbiór par. W obu wariantach najmniejszy błąd na zbiorze walidacyjnym występował już między 2. a 11. epoką, co oznacza, że bez augmentacji sieć szybko dopasowywała się do danych treningowych.

Augmentacja danych

Augmentacja geometryczna opisana w podrozdziale 4.3 zmniejszyła średni EER dla fałszerstw wykwalifikowanych z 24,6% do 20,3%, a dla fałszerstw losowych z 16,1% do 11,1%. Poprawa wystąpiła przy każdym z trzech ziaren, a rozrzut między ziarnami zmalał. Najmniejszy błąd walidacyjny przypadał średnio na 11. epokę zamiast 6., czyli sieć później zaczynała dopasowywać się do danych treningowych.

Sprawdzono również wariant, w którym oprócz zmian geometrycznych kreski podpisu były z prawdopodobieństwem 50% pogrubiane o jeden piksel. Pogrubianie pogorszyło wynik przy każdym ziarnie: średni EER dla fałszerstw wykwalifikowanych wzrósł do 23,0%, a dla losowych do 13,5%. Przekształcenie zastosowane w augmentacji powinno zachowywać informację potrzebną do rozpoznania etykiety [9]. Pogarszający się wynik wskazuje, że grubość kresek niesie informację przydatną do odróżniania fałszerstw. Jest to zgodne z obserwacją z podrozdziału 4.1, że po wyrównaniu ciemności atramentu podpisy prawdziwe i fałszerstwa nadal różnią się prawdopodobnie grubością kresek. Na podstawie przeprowadzonych badań nie da się rozstrzygnąć, czy jest to cecha samych fałszerstw, czy wynik użycia innego długopisu podczas zbierania danych. W dalszych badaniach stosowano tylko augmentację geometryczną.

Wybór obszaru obrazu

Porównano trzy sposoby wyboru obszaru obrazu opisane w podrozdziale 4.1. Przed treningiem przewidywano, że najlepsze będzie przycinanie do podpisu, jednak najmniejszy błąd uzyskano dla całego obrazu. Średni EER dla fałszerstw wykwalifikowanych wyniósł 17,2% wobec 20,3% przy przycinaniu i był mniejszy przy każdym ziarnie, natomiast dla fałszerstw losowych był nieco większy (12,5% wobec 11,1%). Umieszczenie podpisu na dużym tle według środka masy dało najgorszy wynik, 26,2%. W tym wariancie typowy podpis zajmuje na wejściu sieci obszar około 38×91 pikseli, więc szczegóły kształtu zostają utracone.

Ponieważ przy całym obrazie sieć widzi położenie i rozmiar podpisu na kartce, sprawdzono, czy same te cechy pozwalają odróżnić fałszerstwa. Dla każdej pary obliczono różnicę jednej cechy między obydwoma obrazami i potraktowano ją jako miarę podobień-

stwa. EER dla fałszerstw wykwalifikowanych wyniósł 49,3% dla pionowego położenia środka podpisu, 47,0% dla poziomego, 45,5% dla wysokości podpisu, 43,8% dla udziału prostokąta podpisu w powierzchni obrazu i 42,1% dla szerokości podpisu. Położenie podpisu nie niesie więc żadnej informacji o fałszerstwie, a jego rozmiar względem kartki tylko niewielką. Prawdopodobnym wyjaśnieniem przewagi całego obrazu jest to, że przy przycinaniu każdy podpis jest skalowany inaczej, przez co sieć traci informację o jego rzeczywistym rozmiarze i grubości kresek. Podobną zależność zaobserwowano dla prostej metody porównawczej, której EER przy przycinaniu wzrastał z 38,0% do 42,1% (podrozdział 4.1). Hipotezy tej nie sprawdzono osobnym eksperymentem. W dalszych badaniach stosowano cały obraz.

Rozmiar wejścia

Dla całego obrazu porównano cztery rozmiary wejścia sieci, przy czym wynik dla rozmiaru 128×256 odpowiada wierszowi „cały obraz” w tabeli 5.1. Dzięki uśrednianiu do siatki 2×4 (podrozdział 4.2) we wszystkich przypadkach użyto tej samej sieci. Na fałszerstwach wykwalifikowanych rozmiar wejścia prawie nie wpływał na wynik, który wynosił od 16,6% do 19,2%, przy rozrzucie między ziarnami do 1,9 punktu procentowego. Wejście 256×512 dało najmniejszy błąd na zbiorze walidacyjnym przy każdym ziarnie (11,7% wobec 13,5% dla 128×256), ale na zbiorze testowym błąd dla fałszerstw wykwalifikowanych był o 2 punkty procentowe większy. Zbiór walidacyjny i testowy wskazywały więc różne warianty, co pokazuje, że 10 osób nie wystarcza do wiarygodnego wyboru między wariantami różniącymi się o 1–2 punkty procentowe. Trening dla wejścia 256×512 trwał około 70 minut zamiast 9, dlatego pozostawiono rozmiar 128×256.

5.3. Wpływ różnic niezwiązanych z kształtem podpisu

W podrozdziałach 3.2 i 4.1 pokazano, że podpisy prawdziwe i fałszerstwa w zbiorze CEDAR różnią się jasnością tła i ciemnością atramentu. Aby sprawdzić, jak bardzo te różnice zawyżyłyby wyniki, sieć wytrenowano bez kroków, które je usuwają. W wariancie bez usuwania tła pominięto również wyrównanie atramentu, ponieważ wymaga ono wcześniejszego usunięcia tła. Zbadano też, czy sieć potrzebuje fałszerstw wykwalifikowanych w zbiorze treningowym. Wszystkie warianty trenowano z augmentacją geometryczną i przycinaniem do podpisu, a wyniki porównano z wariantem z pełnym przygotowaniem obrazów. Zestawiono je w tabeli 5.2.

Tabela 5.2. Wyniki wariantów bez usuwania tła, bez wyrównania atramentu i bez fałszerstw wykwalifikowanych (w procentach, średnia z trzech treningów; FAR i FRR przy progu z walidacji)

Wariant	EER		FAR		FRR
	wykw.	losowe	wykw.	losowe	
pełne przygotowanie	20,3	11,1	26,8	8,2	14,5
bez wyrównania atramentu	20,0	12,6	29,9	13,9	13,1
bez usuwania tła	1,8	14,1	2,9	42,6	1,0
bez fałszerstw w treningu	26,4	9,2	29,6	5,3	22,2
bez fałszerstw w ogóle	27,8	10,5	64,4	15,6	3,9

Jasność tła

Bez usuwania tła sieć osiągnęła EER dla fałszerstw wykwalifikowanych równy 1,8% $\pm$ 0,7, czyli prawie bezbłędne wykrywanie fałszerstw. Jednocześnie wynik dla fałszerstw losowych pogorszył się z 11,1% do 14,1%, a przy progu wyznaczonym na walidacji model akceptował 42,6% par podpisów dwóch różnych osób, wobec 8,2% przy pełnym przygotowaniu. Oznacza to, że sieć nauczyła się porównywać przede wszystkim jasność tła. Para z fałszerstwem wykwalifikowanym zawsze zawiera jeden obraz z ciemniejszym tłem i jeden z jaśniejszym, więc łatwo ją odrzucić, natomiast para dwóch podpisów prawdziwych różnych osób ma podobne tło i często jest błędnie akceptowana. Model wydaje się więc bardzo dobry na fałszerstwach wykwalifikowanych, ale gorzej rozpoznaje, czy dwa podpisy należą do tej samej osoby.

Jest to przykład uczenia na skróty, opisanego w podrozdziale 2.6 [11]. Regułą pozwalającą odróżnić fałszerstwa jest tu różnica jasności tła wynikająca ze sposobu przygotowania zbioru, a nie kształt podpisu. Wynik ten pokazuje, że usunięcie tła jest konieczne, a bardzo małe błędy uzyskiwane na zbiorze CEDAR mogą wynikać z takiej różnicy, a nie z rozpoznawania podpisów.

Ciemność atramentu

Bez wyrównania ciemności atramentu wynik dla fałszerstw wykwalifikowanych praktycznie się nie zmienił (20,0% wobec 20,3%), a dla fałszerstw losowych był nieco gorszy (12,6% wobec 11,1%). Przed treningiem przewidywano wyraźny spadek błędu dla fałszerstw, ponieważ sama ciemność atramentu pozwalała wykryć fałszerstwo z EER równym 21,1% (podrozdział 4.1), jednak przewidywanie się nie sprawdziło. Możliwe, że sieć nie korzysta z ciemności kresek albo uzyskuje tę samą informację z ich grubości. Wyrównanie atramentu pozostawiono, ponieważ nie pogarsza wyniku dla fałszerstw wykwalifikowanych, a dla fałszerstw losowych daje nieco lepszy wynik.

Trening bez fałszerstw wykwalifikowanych

W rzeczywistym zastosowaniu fałszerstwa podpisu nowej osoby zwykle nie są dostępne [1]. Dlatego sprawdzono, jak działa sieć trenowana bez fałszerstw wykwalifikowanych. Dla każdej osoby treningowej losowano 48 par pozytywnych i 48 par z fałszerstwami losowymi, tak aby klasy pozostały równoliczne. W pierwszym wariancie fałszerstwa wykwalifikowane były używane tylko na zbiorze walidacyjnym do wyboru epoki i progu, a w drugim nie były używane wcale.

Bez fałszerstw w treningu EER dla fałszerstw wykwalifikowanych wzrósł z 20,3% do 26,4%, a gdy nie używano ich także na walidacji, do 27,8%. Pogorszenie wystąpiło przy każdym ziarnie. Podobny spadek zaobserwowano w pracy [3] na zbiorze GPDS300 (podrozdział 2.5). Fałszerstwa w treningu poprawiają więc wynik o około 6 punktów procentowych, przy czym nie wiadomo, czy sieć uczy się z nich cech fałszowania, czy pozostałych różnic wynikających ze sposobu zbierania danych, takich jak grubość kresek. Nawet bez fałszerstw sieć była jednak wyraźnie lepsza od prostej metody porównawczej, dla której EER przy przycinaniu wynosił 42,1%, więc uczy się przede wszystkim kształtu podpisu. Dla fałszerstw losowych wynik był lepszy niż przy pełnym treningu (9,2% wobec 11,1%), ponieważ par z fałszerstwami losowymi było w treningu dwa razy więcej.

Wariant bez fałszerstw pokazuje też problem z wyborem progu. Próg wyznaczony na parach z fałszerstwami losowymi okazał się zbyt łagodny dla fałszerstw wykwalifikowanych: model akceptował 64,4% z nich, odrzucając tylko 3,9% par pozytywnych. Bez przykładów fałszerstw wykwalifikowanych nie da się więc dobrze ustawić progu. W modelu końcowym fałszerstwa wykwalifikowane pozostały w zbiorze treningowym i walidacyjnym.

5.4. Walidacja krzyżowa i wynik końcowy

Sposób przeprowadzenia

Wyniki z poprzednich podrozdziałów uzyskano na jednym podziale osób, w którym zbiór testowy zawiera tylko 10 osób, a w eksperymencie z rozmiarem wejścia zbiór walidacyjny i testowy wskazały różne warianty. Aby sprawdzić, jak bardzo wynik zależy od tego, które osoby trafiły do zbioru testowego, końcowy wariant modelu oceniono pięciokrotną walidacją krzyżową.

Wszystkie 55 osób podzielono losowo na pięć grup po 11 osób. W każdej z pięciu części jedna grupa stanowiła zbiór testowy, a spośród pozostałych 44 osób losowano 10 do zbioru walidacyjnego i 34 do treningowego. Każda osoba znalazła się więc w zbiorze testo-

wym dokładnie raz. Pary walidacyjne i testowe losowano raz dla każdej części, tym samym sposobem co w podrozdziale 3.4, co daje 1056 par testowych w każdej części. Pary treningowe losowano na nowo w każdej epoce. Podział zapisano w pliku, a wszystkie losowania wykonano z ustalonymi ziarnami. W każdej części sieć trenowano z trzema ziarnami, czyli łącznie wykonano 15 treningów. Zastosowano najlepsze ustawienia z podrozdziału 5.2: cały obraz, wejście 128×256, augmentację geometryczną, usuwanie tła, wyrównanie atramentu i fałszerstwa wykwalifikowane w treningu. Na tych samych parach testowych obliczono również EER prostej metody porównawczej z podrozdziału 3.2, dla obrazów przygotowanych tak samo jak dla sieci.

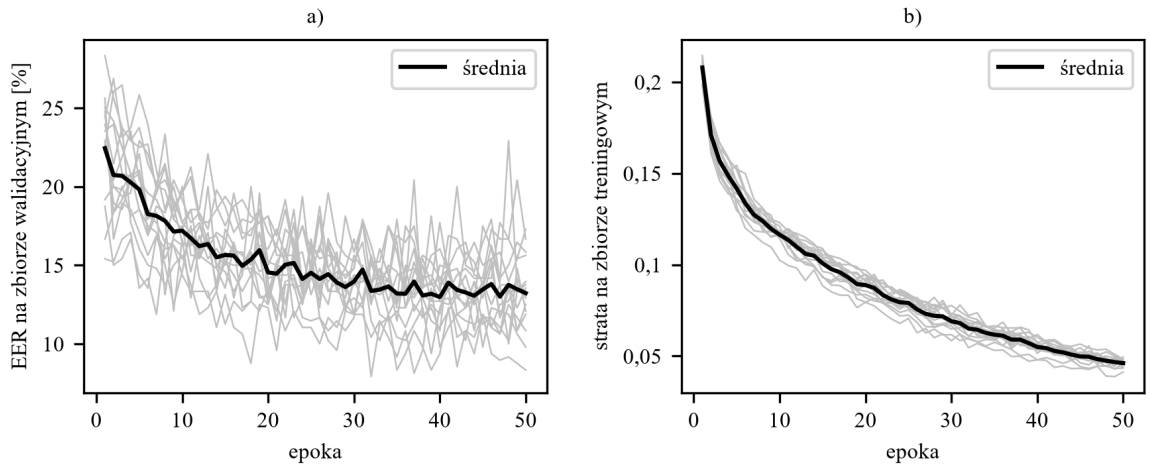
Liczba epok

Przy treningu przez 30 epok najmniejszy błąd walidacyjny przypadał zwykle między 18. a 30. epoką, a w jednym przypadku na ostatnią epokę. Dlatego wszystkie 15 treningów powtórzono dla 50 epok. Ponieważ trening z tym samym ziarnem daje identyczny wynik, pierwsze 30 epok obu treningów jest takie samo, a różnica może pojawić się tylko wtedy, gdy najlepsza epoka wypada po 30. Sprawdzono to bezpośrednio: w 4 treningach najlepsza epoka nie przekroczyła 30 i uzyskano wynik identyczny jak przy 30 epokach. W pozostałych 11 treningach najlepsza epoka wypadła po 30. Średni EER na zbiorze walidacyjnym zmniejszył się z 12,1% do 10,7%, dla fałszerstw wykwalifikowanych z 20,4% do 19,4% (poprawa w 8 treningach, pogorszenie w 2), a dla fałszerstw losowych z 13,6% do 12,0% (poprawa w 10 treningach, pogorszenie w 1).

Przebieg treningu przedstawiono na rys. 5.1. Średni błąd walidacyjny maleje mniej więcej do 40. epoki, a później pozostaje na stałym poziomie około 13,5%, podczas gdy strata na zbiorze treningowym nadal spada. Dalsze wydłużanie treningu nie powinno więc poprawić wyniku, ponieważ sieć coraz lepiej dopasowuje się do osób treningowych, ale nie do nowych osób. Błąd walidacyjny zmienia się z epoki na epokę nawet o kilka punktów procentowych, więc wybór najlepszej epoki zależy w pewnym stopniu od przypadku. Model końcowy trenowano przez 50 epok.

Zmniejszanie kroku uczenia

Przy stałym kroku uczenia błąd walidacyjny zmieniał się z epoki na epokę nawet o kilka punktów procentowych (rys. 5.1), dlatego sprawdzono, czy pomoże stopniowe zmniejszanie kroku uczenia w czasie treningu. Zastosowano harmonogram cosinusowy [17], w którym



Rys. 5.1. Przebieg treningu przez 50 epok ze stałym krokiem uczenia w walidacji krzyżowej: a) EER na zbiorze walidacyjnym, b) strata na zbiorze treningowym; szare linie – 15 pojedynczych treningów, czarna linia – średnia

krok uczenia w epoce e wynosi

$$\eta_e = \frac{\eta_0}{2}\left(1+\cos\frac{\pi\,(e-1)}{E}\right), \tag{5.1}$$

gdzie $\eta_0 = 0{,}001$ jest początkowym krokiem uczenia, a $E = 50$ liczbą epok. Krok uczenia maleje więc płynnie od 0,001 w pierwszej epoce do wartości bliskiej zera w ostatniej. Wszystkie 15 treningów walidacji krzyżowej powtórzono z tym harmonogramem.

Przed treningiem przewidywano, że najlepsze epoki przesuną się na koniec treningu, a wynik na zbiorze testowym nieznacznie się poprawi. Zmniejszanie kroku uczenia wygładziło przebieg treningu: średnia zmiana błędu walidacyjnego między kolejnymi epokami w epokach 41–50 zmalała z 1,6 do 0,4 punktu procentowego. Najlepsze epoki wypadały jednak głównie między 21. a 40. epoką, a wynik na zbiorze testowym się nie poprawił. EER dla fałszerstw wykwalifikowanych wyniósł 19,6% $\pm$ 2,8 wobec 19,4% $\pm$ 3,5 przy stałym kroku uczenia (wynik lepszy w 8 treningach, gorszy w 7), a dla fałszerstw losowych 13,3% $\pm$ 3,1 wobec 12,0% $\pm$ 1,8. Błąd na zbiorze walidacyjnym był wyższy (11,9% wobec 10,7%), prawdopodobnie dlatego, że przy gładszym przebiegu treningu rzadziej zdarzały się przypadkowo niskie wartości błędu, które przy stałym kroku uczenia były wybierane jako najlepsza epoka. Ponieważ zmniejszanie kroku uczenia nie poprawiło wyniku, w modelu końcowym pozostawiono stały krok uczenia.

Wyniki

Wyniki dla poszczególnych części zestawiono w tabeli 5.3.

Tabela 5.3. EER w walidacji krzyżowej w procentach (sieć: średnia z trzech treningów w części; wiersz „średnia” – średnia ± odchylenie standardowe z 15 treningów sieci i z 5 części dla metody porównawczej)

Część	Sieć, 30 epok		Sieć, 50 epok		Metoda porównawcza	
	wykw.	losowe	wykw.	losowe	wykw.	losowe
1	23,1	14,5	22,6	13,1	36,3	31,8
2	16,5	16,7	17,3	13,4	41,3	37,9
3	22,7	10,0	21,8	9,9	34,8	29,9
4	18,9	13,9	15,5	10,9	43,2	34,1
5	20,9	12,9	19,9	12,6	39,7	29,9
średnia	20,4 ± 3,1	13,6 ± 2,4	19,4 ± 3,5	12,0 ± 1,8	39,0 ± 3,1	32,7 ± 3,0

Ostatecznie sieć uzyskała EER równy 19,4% ± 3,5 dla fałszerstw wykwalifikowanych i 12,0% ± 1,8 dla fałszerstw losowych. Prosta metoda porównawcza na tych samych parach osiągnęła 39,0% i 32,7%, więc sieć zmniejszyła błąd mniej więcej o połowę. Sieć była lepsza w każdej części, a nawet najgorszy z 15 treningów (25,3% dla fałszerstw wykwalifikowanych) był lepszy od najlepszej części metody porównawczej (34,8%).

Wynik walidacji krzyżowej dla 30 epok (20,4%) jest wyraźnie gorszy niż wynik tego samego wariantu na stałym podziale (17,2% ± 0,5, tabela 5.1). Stały podział okazał się więc łatwiejszy od przeciętnego. Część 5 zawiera wszystkie 10 osób testowych ze stałego podziału i jedną dodatkową osobę, a mimo to dała 20,9%. Różnią się w niej jednak osoby walidacyjne i liczba osób treningowych, a pary testowe zostały wylosowane na nowo. Średnie wyniki poszczególnych części wahają się od 16,5% do 23,1%, a ich odchylenie standardowe wynosi około 2,4 punktu procentowego, podczas gdy średnie odchylenie między ziarnami w obrębie jednej części wynosi około 1,4 punktu procentowego (wartości dla 30 epok). Wybór osób testowych wpływa więc na wynik bardziej niż ziarno, choć w niektórych częściach różnice między ziarnami także są duże, na przykład w części 3 od 17,7% do 25,8%. Części trudne dla sieci nie pokrywają się z częściami trudnymi dla metody porównawczej. Na przykład część 2 była najłatwiejsza dla sieci przy 30 epokach, a jedną z najtrudniejszych dla metody porównawczej.

Przy progu wyznaczonym na zbiorze walidacyjnym sieć trenowana przez 50 epok miała dla fałszerstw wykwalifikowanych FAR równy 18,5% ± 7,8 i FRR równy 21,4% ± 4,4, a dla fałszerstw losowych FAR równy 7,3% ± 2,5. FAR dla fałszerstw wykwalifikowanych wahał się w poszczególnych treningach od 9,1% do 32,6%. Próg wyznaczony na 10 osobach walidacyjnych przenosi się więc na nowe osoby w niestabilny sposób, a w praktycznym zastosowaniu potrzebny byłby większy zbiór do jego wyznaczenia.

Ustawienia modelu wybrano na stałym podziale osób, a jego osoby testowe występują w części 5 walidacji krzyżowej. Wynik walidacji krzyżowej nie jest więc całkowicie niezależny od wyboru ustawień i może być nieznacznie optymistyczny.

5.5. Porównanie z wynikami z literatury

Uzyskany wynik jest wyraźnie gorszy od wyników podawanych dla zbioru CEDAR w literaturze (podrozdziały 2.3 i 2.5). Sieć SigNet, oparta tak jak w niniejszej pracy na splotowej sieci syjamskiej i funkcji straty kontrastowej, uzyskała na tym zbiorze dokładność 100% przy FAR i FRR równych zero [3]. Wynik ten otrzymano jednak w innych warunkach. Zbiór testowy zawierał 5 osób z jednego losowego podziału, a dokładność obliczano jako najlepszą wartość spośród wszystkich progów sprawdzonych na zbiorze testowym, czyli próg był dobierany na tych samych danych, na których oceniano model [3]. W opisie przygotowania obrazów nie wspomniano o usuwaniu tła. Jak pokazano w podrozdziale 5.3, bez usuwania tła sieć opisana w niniejszej pracy osiągnęła EER równy 1,8%, więc prawie bezbłędny wynik może być skutkiem różnicy jasności tła. Bez powtórzenia badań z pracy [3] nie da się jednak tego potwierdzić.

Najlepszy wynik w tabeli 2.1, EER równy 4,63% [6], uzyskano w podejściu zależnym od autora, w którym dla każdej osoby trenowano osobny klasyfikator na podstawie 12 jej podpisów wzorcowych. Model miał więc do dyspozycji podpisy osoby, którą weryfikował, podczas gdy sieć z niniejszej pracy porównuje dwa podpisy osoby, której nigdy nie widziała. Pozostałe wyniki w tej tabeli to w większości średni błąd AER, a nie EER, uzyskany przy różnej liczbie podpisów wzorcowych.

Wyniki z literatury nie są więc bezpośrednio porównywalne z wynikiem niniejszej pracy. W pracy zastosowano surowszy sposób oceny: osoby testowe nie występowały w treningu, próg nie był dobierany na zbiorze testowym, wynik uśredniono z 15 treningów obejmujących wszystkie 55 osób, a różnicę jasności tła usunięto przed treningiem.

6. Podsumowanie i wnioski końcowe

Literatura

[1] Hafemann L.G., Sabourin R., Oliveira L.S.: Offline Handwritten Signature Verification — Literature Review. 7th International Conference on Image Processing Theory, Tools and Applications (IPTA), 2017.

[2] Bromley J., Guyon I., LeCun Y., Säckinger E., Shah R.: Signature Verification using a „Siamese" Time Delay Neural Network. Advances in Neural Information Processing Systems 6 (NIPS 1993), str. 737–744.

[3] Dey S., Dutta A., Toledo J.I., Ghosh S.K., Lladós J., Pal U.: SigNet: Convolutional Siamese Network for Writer Independent Offline Signature Verification. arXiv:1707.02131, 2017.

[4] Jain A.K., Ross A., Prabhakar S.: An Introduction to Biometric Recognition. IEEE Transactions on Circuits and Systems for Video Technology, vol. 14, nr 1, 2004, str. 4–20.

[5] Kalera M.K., Srihari S.N., Xu A.: Offline Signature Verification and Identification Using Distance Statistics. International Journal of Pattern Recognition and Artificial Intelligence, vol. 18, nr 7, 2004, str. 1339–1360.

[6] Hafemann L.G., Sabourin R., Oliveira L.S.: Learning Features for Offline Handwritten Signature Verification using Deep Convolutional Neural Networks. Pattern Recognition, vol. 70, 2017, str. 163–176.

[7] Goodfellow I., Bengio Y., Courville A.: Deep Learning. MIT Press, 2016, `https://www.deeplearningbook.org`. Dostęp 12.10.2026.

[8] Hadsell R., Chopra S., LeCun Y.: Dimensionality Reduction by Learning an Invariant Mapping. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2006, str. 1735–1742.

[9] Shorten C., Khoshgoftaar T.M.: A survey on Image Data Augmentation for Deep Learning. Journal of Big Data, vol. 6, nr 60, 2019.

[10] Li Y., Chen C.L.P., Zhang T.: A Survey on Siamese Network: Methodologies, Applications, and Opportunities. IEEE Transactions on Artificial Intelligence, vol. 3, nr 6, 2022, str. 994–1014.

[11] Geirhos R., Jacobsen J.-H., Michaelis C., Zemel R., Brendel W., Bethge M., Wichmann F.A.: Shortcut Learning in Deep Neural Networks. Nature Machine Intelligence, vol. 2, nr 11, 2020, str. 665–673.

[12] CEDAR Signature Dataset, `https://www.kaggle.com/datasets/shreelakshmigp/cedardataset`. Dostęp 29.09.2026.

[13] Otsu N.: A Threshold Selection Method from Gray-Level Histograms. IEEE Transactions on Systems, Man, and Cybernetics, vol. SMC-9, nr 1, 1979, str. 62–66.

[14] Ioffe S., Szegedy C.: Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. Proceedings of the 32nd International Conference on Machine Learning (ICML), PMLR vol. 37, 2015, str. 448–456.

[15] Srivastava N., Hinton G., Krizhevsky A., Sutskever I., Salakhutdinov R.: Dropout: A Simple Way to Prevent Neural Networks from Overfitting. Journal of Machine Learning Research, vol. 15, 2014, str. 1929–1958.

[16] Kingma D.P., Ba J.: Adam: A Method for Stochastic Optimization. International Conference on Learning Representations (ICLR), 2015.

[17] Loshchilov I., Hutter F.: SGDR: Stochastic Gradient Descent with Warm Restarts. International Conference on Learning Representations (ICLR), 2017.

POLITECHNIKA RZESZOWSKA im. I. Łukasiewicza Rzeszów, 2026
Wydział Elektrotechniki i Informatyki

STRESZCZENIE PRACY DYPLOMOWEJ INŻYNIERSKIEJ

ZASTOSOWANIE ALGORYTMÓW SZTUCZNEJ INTELIGENCJI DO ROZPOZNAWANIA AUTENTYCZNOŚCI PODPISU

Autor: Maciej Pereślucha, nr albumu: EF-177139
Opiekun: dr inż. Paweł Górka
Słowa kluczowe: max. 5 słów kluczowych w 2 wierszach, oddzielanych przecinkami

Treść streszczenia po polsku

RZESZOW UNIVERSITY OF TECHNOLOGY Rzeszow, 2026
Faculty of Electrical and Computer Engineering

BSC THESIS ABSTRACT

APPLICATION OF ARTIFICIAL INTELLIGENCE ALGORITHMS FOR SIGNATURE AUTHENTICITY RECOGNITION

Author: Maciej Pereślucha, Student's ID: EF-177139
Supervisor: Paweł Górka, PhD, Eng.
Key words: max. five keywords in English

Treść streszczenia po angielsku