



**WYDZIAŁ
ELEKTROTECHNIKI
I INFORMATYKI**
POLITECHNIKI RZESZOWSKIEJ

Maciej Pereślucha

Zastosowanie algorytmów sztucznej inteligencji do
rozpoznawania autentyczności podpisu

PRACA INŻYNIERSKA

Opiekun pracy:
dr inż. Paweł Górka

Rzeszów, 2026

Spis treści

1. Wprowadzenie	5
2. Metody weryfikacji podpisu – przegląd literatury	7
3. Zbiór danych i jego przygotowanie	9
3.1. Zbiór CEDAR	9
3.2. Analiza eksploracyjna danych	10
3.3. Podział na zbiory niezależne od autora	12
3.4. Budowa par podpisów	13
4. Model sieci syjamskiej	15
5. Badania eksperymentalne i wyniki	17
6. Podsumowanie i wnioski końcowe	19
Literatura	20

1. Wprowadzenie

Podpis odręczny jest jednym z najczęściej używanych sposobów potwierdzania tożsamości, na przykład w bankach, u notariusza czy w urzędach. Sprawdzaniem, czy podpis jest prawdziwy, zajmują się zwykle biegli grafolodzy, jednak taka ocena zajmuje dużo czasu i w pewnym stopniu zależy od doświadczenia osoby, która ją wykonuje. Automatyczna weryfikacja podpisu jest badana od kilkudziesięciu lat, ale nadal pozostaje problemem otwartym. Rozwój uczenia głębokiego sprawił, że sieci neuronowe potrafią same nauczyć się cech, po których można odróżnić podpisy różnych osób, bez ręcznego projektowania tych cech [1].

Najprostszym pomysłem byłoby nauczanie sieci rozpoznawania podpisów każdej osoby osobno, tak jak w zwykłym zadaniu klasyfikacji. Takie podejście ma jednak dwie wady. Po pierwsze, od jednej osoby dostępnych jest zwykle niewiele podpisów — w zbiorze użytym w tej pracy są to 24 podpisy na osobę. Po drugie, dodanie do systemu każdej nowej osoby wymagałoby ponownego trenowania modelu. Rozwiązaniem jest sieć syjamska, która składa się z dwóch jednakowych podsieci i zamiast odpowiadać na pytanie, do kogo należy podpis, porównuje ze sobą dwa podpisy i mierzy, jak bardzo są do siebie podobne [2]. Dzięki temu sieć może być stosowana także do osób, których podpisów nie widziała podczas treningu [3].

W pracy wykorzystano podpisy w postaci zeskanowanych obrazów. Taki wariant nazywa się weryfikacją statyczną (ang. *offline*), w odróżnieniu od weryfikacji dynamicznej (ang. *online*), w której podpis składany jest na tablecie rejestrującym na przykład prędkość ruchu pióra. Na obrazie tych informacji nie ma, widoczny jest tylko kształt podpisu. Najtrudniejsze do wykrycia są fałszerstwa wykwalifikowane, czyli podpisy podrobione przez osobę, która wcześniej ćwiczyła naśladowanie oryginału [4]. Wstępna analiza danych wykonana w ramach pracy pokazała, że proste porównanie obrazów piksel po pikselu myli się w ponad jednej trzeciej przypadków, dlatego potrzebna jest bardziej zaawansowana metoda.

Celem pracy było opracowanie systemu, który na podstawie zeskanowanego obrazu sprawdza, czy podpis jest autentyczny, oraz ocena jego skuteczności. System oparto na sieci syjamskiej i zaprojektowano tak, aby działał również dla osób, których podpisy nie były używane podczas treningu. Zakres pracy obejmował:

- przegląd literatury dotyczącej weryfikacji podpisu i sieci syjamskich,

- analizę zbioru podpisów CEDAR,
- przygotowanie danych, w tym podział osób na osobne zbiory treningowy, walityczny i testowy oraz utworzenie par podpisów,
- implementację sieci syjamskiej w języku Python,
- trening sieci i ocenę jej skuteczności na zbiorze testowym,
- analizę otrzymanych wyników.

2. Metody weryfikacji podpisu – przegląd literatury

3. Zbiór danych i jego przygotowanie

3.1. Zbiór CEDAR


Do trenowania i testowania modelu wykorzystano zbiór podpisów CEDAR, przygotowany w ośrodku Center of Excellence for Document Analysis and Recognition Uniwersytetu w Buffalo. Zbiór zawiera podpisy 55 osób, z których każda złożyła 24 podpisy prawdziwe w wyznaczonym polu o wymiarach 2×2 cale. Fałszerstwa przygotowało około 20 innych osób, które miały jak najdokładniej podrobić podpisy osób ze zbioru, dzięki czemu dla każdej osoby zebrano 24 fałszerstwa wykwalifikowane. Podpisy zeskanowano z rozdzielczością 300 dpi w 8-bitowej skali szarości i zapisano w formacie PNG [4]. Podstawowe parametry zbioru zestawiono w tabeli 3.1.

Tabela 3.1. Podstawowe parametry zbioru CEDAR

Parametr	Wartość
liczba osób	55
podpisy prawdziwe na osobę	24
fałszerstwa wykwalifikowane na osobę	24
podpisy prawdziwe łącznie	1320
fałszerstwa łącznie	1320
wszystkie obrazy	2640

Zbiór CEDAR jest często wykorzystywany w pracach dotyczących weryfikacji podpisu, między innymi w [3, 5], dzięki czemu wyniki uzyskane w niniejszej pracy można porównać z wynikami innych autorów.

W pracy użyto kopii zbioru udostępnionej w serwisie Kaggle [6]. Obrazy podzielone są na dwa katalogi: `full_org` z podpisami prawdziwymi oraz `full_forg` z fałszerstwami. Nazwa pliku zawiera numer osoby i numer podpisu, na przykład `original_1_5.png` to piąty prawdziwy podpis osoby nr 1, a `forgeries_1_5.png` to piąte fałszerstwo jej podpisu. Według autorów zbioru wszystkie obrazy zapisano w skali szarości, jednak w użytej kopii część plików ma inne tryby kolorów, co opisano w podrozdziale 3.2. Na rys. 3.1 przedstawiono przykładowe podpisy jednej osoby ze zbioru.



Rys. 3.1. Przykładowe podpisy jednej osoby ze zbioru CEDAR: dwa podpisy prawdziwe (a, b) i fałszerstwo wykwalifikowane (c)

3.2. Analiza eksploracyjna danych

Przed przygotowaniem danych do treningu przeprowadzono analizę zbioru, aby sprawdzić jego poprawność i wykryć cechy obrazów, które mogłyby utrudnić trening sieci albo zafałszować wyniki. Analizę wykonano w języku Python z użyciem bibliotek PIL i NumPy.

Najpierw sprawdzono kompletność zbioru. W katalogu `full_org` znajduje się 1320 obrazów i tyle samo w katalogu `full_forg`, po 24 dla każdej z 55 osób. Dla każdego pliku obliczono skrót MD5, co pozwoliło stwierdzić, że w zbiorze nie ma powtórzonych obrazów. Sprawdzono także, czy wszystkie pliki dają się poprawnie otworzyć, i żaden nie okazał się uszkodzony. Oprócz obrazów w katalogach znajdują się jedynie pliki systemowe `Thumbs.db`, które pominięto.


Następnie sprawdzono tryby kolorów obrazów. Według autorów zbioru wszystkie podpisy zapisano w 8-bitowej skali szarości [4], jednak w użytej kopii podpisy prawdziwe zapisane są w trybach RGBA (cztery kanały) i L (skala szarości), a fałszerstwa w trybach P (paleta kolorów) i RGBA. Kolor nie niesie informacji o kształcie podpisu, dlatego wszystkie obrazy przy wczytywaniu zamieniane są na skalę szarości.

Obrazy w zbiorze nie mają wspólnego rozmiaru. Wśród 1320 podpisów prawdziwych występuje 1095 różnych rozmiarów, a wśród fałszerstw 1006. Mediana rozmiaru wynosi 577×349 pikseli dla podpisów prawdziwych i 576×336 pikseli dla fałszerstw (szerokość $\times$ wysokość), a szerokość obrazów waha się od 264 do 888 pikseli. Sieć wymaga obrazów o jednakowym rozmiarze, dlatego wszystkie obrazy trzeba przeskalować. Ponieważ podpisy są wyraźnie szersze niż wyższe (proporcja około 1,7:1), wejście sieci powinno mieć kształt prostokąta, a nie kwadratu. Okazało się również, że rozmiar

obrazu niemal jednoznacznie wskazuje osobę, do której należy podpis: 85,4% rozmiarów występujących wśród podpisów prawdziwych i 78,1% wśród fałszerstw pojawia się tylko u jednej osoby. Gdyby obrazy nie zostały ujednolicone, sieć mogłaby nauczyć się rozpoznawać osobę po rozmiarze obrazu, a nie po kształcie podpisu.

Prostokąt obejmujący podpis zajmuje średnio około 60% powierzchni obrazu (60,1% dla podpisów prawdziwych i 58,6% dla fałszerstw), a resztę stanowi puste tło. Za piksele podpisu uznano piksele o jasności mniejszej niż 200. Przeskalowanie całego obrazu do niewielkiego wejścia sieci oznaczałoby, że znaczna jego część przypadłaby na tło, dlatego przed skalowaniem obrazy przycinane są do prostokąta zawierającego podpis.

Najważniejszym wynikiem analizy okazała się różnica w jasności tła między podpisami prawdziwymi a fałszerstwami. Dla każdego obrazu obliczono medianę jasności pikseli, która, ponieważ podpis zajmuje tylko niewielką część pikseli, odpowiada w przybliżeniu jasności tła. Rozkład tej wartości przedstawiono na rys. 3.2.



Rys. 3.2. Rozkład mediany jasności obrazów dla podpisów prawdziwych i fałszerstw w zbiorze CEDAR

Dla podpisów prawdziwych mediana mieści się w przedziale od 234 do 245 (średnio 239,8), a dla fałszerstw od 249 do 255 (średnio 253,5), przy czym 513 z 1320 fałszerstw ma tło idealnie białe. Przedziały te nie nakładają się, więc pojedynczy próg jasności równy 247 pozwala bezbłędnie oddzielić wszystkie podpisy prawdziwe od fałszerstw bez analizowania samego podpisu. Sieć trenowana na takich danych mogłaby wykorzystać tę różnicę zamiast uczyć się cech podpisu, co zawyżyłoby wyniki dla fałszerstw wykwalifikowanych. Na podstawie dostępnych informacji nie da się ustalić, czy różnica ta pochodzi z oryginalnego skanowania, czy z późniejszej konwersji plików. Sposób jej usunięcia opisano w rozdziale 4.

Na koniec sprawdzono, czy do odróżniania podpisów wystarczy proste porównanie obrazów. Obrazy przeskalowano do rozmiaru 128×128 pikseli i dla wszystkich par opisanych w podrozdziale 3.4 obliczono współczynnik korelacji Pearsona między wartościami pikseli. Średnia korelacja wyniosła 0,158 (odchylenie standardowe 0,090) dla par dwóch podpisów prawdziwych tej samej osoby, 0,104 (0,069) dla par z fałszerstwem wykwalifikowanym oraz 0,083 (0,061) dla par podpisów dwóch różnych osób. Rozkłady te w dużym stopniu się nakładają. Korelację potraktowano jako miarę podobieństwa i wybrano próg, przy którym odsetek błędnie odrzuconych par prawdziwych jest równy odsetkowi błędnie zaakceptowanych par fałszywych. Błąd w tym punkcie, nazywany równym współczynnikiem błędów (ang. *equal error rate*, EER), wyniósł 38,0% dla fałszerstw wykwalifikowanych i 32,3% dla fałszerstw losowych. Prosta metoda myli się więc w ponad jednej trzeciej przypadków, co uzasadnia zastosowanie sieci neuronowej. Wynik ten posłuży również jako punkt odniesienia przy ocenie sieci w rozdziale 5.

3.3. Podział na zbiory niezależne od autora

W weryfikacji podpisu wyróżnia się dwa podejścia. W podejściu zależnym od autora (ang. *writer-dependent*) dla każdej osoby trenuje się osobny model, natomiast w podejściu niezależnym od autora (ang. *writer-independent*) jeden model służy do weryfikacji podpisów dowolnych osób [1]. W drugim przypadku osoby dzieli się na rozłączne zbiory treningowy i testowy, dzięki czemu system nie wymaga ponownego trenowania po dodaniu nowej osoby [3].

W niniejszej pracy zastosowano podejście niezależne od autora. Osoby ze zbioru CEDAR podzielono losowo na trzy rozłączne grupy: 35 osób do zbioru treningowego, 10 do walidacyjnego i 10 do testowego. Liczbę podpisów w każdym ze zbiorów przedstawiono w tabeli 3.2.

Tabela 3.2. Podział zbioru CEDAR na zbiory treningowy, walidacyjny i testowy

Zbiór	Liczba osób	Podpisy prawdziwe	Fałszerstwa
treningowy	35	840	840
walidacyjny	10	240	240
testowy	10	240	240
razem	55	1320	1320

Zbiór treningowy służy do uczenia sieci, zbiór walidacyjny do wyboru progu decyzyjnego i porównywania wariantów modelu, a zbiór testowy wyłącznie do końcowej

oceny. Żadna osoba nie występuje w więcej niż jednym zbiorze, więc wynik na zbiorze testowym pokazuje, jak model radzi sobie z podpisami osób, których wcześniej nie widział. Losowanie wykonano z ustalonym ziarnem generatora liczb losowych (ang. *seed*), a wynik podziału zapisano w pliku, dzięki czemu podział jest za każdym razem taki sam i wszystkie eksperymenty korzystają z tych samych grup osób.

W literaturze stosowane są różne sposoby podziału zbioru CEDAR. Na przykład w pracy [3] do treningu użyto 50 osób, a do testu 5. Z kolei w pracy [4] podzielono podpisy, a nie osoby: 16 podpisów każdej osoby użyto do treningu, a 8 do testu, więc te same osoby występowały w obu zbiorach. Wyniki uzyskane przy różnych sposobach podziału nie są więc bezpośrednio porównywalne, co uwzględniono przy analizie wyników w rozdziale 5.

3.4. Budowa par podpisów

Sieć syjamska uczy się na parach podpisów, z których każda jest oznaczona jako para pozytywna (oba podpisy prawdziwe i należące do tej samej osoby) albo para negatywna. Pary zbudowano osobno w każdym ze zbiorów opisanych w podrozdziale 3.3, tak aby oba podpisy w parze zawsze pochodziły od osób z tego samego zbioru. Wykorzystano trzy rodzaje par.

Pary pozytywne utworzono z podpisów prawdziwych jednej osoby. Z 24 podpisów można utworzyć 276 różnych par, z których dla każdej osoby wylosowano 48. Pary negatywne z fałszerstwami wykwalifikowanymi utworzono, łącząc podpis prawdziwy osoby z fałszerstwem jej podpisu. Spośród 576 możliwych połączeń (24×24) dla każdej osoby wylosowano 24 pary. Pary negatywne z fałszerstwami losowymi utworzono, łącząc każdy z 24 podpisów prawdziwych osoby z losowo wybranym podpisem prawdziwym innej osoby z tego samego zbioru. Taki sposób symulowania fałszerstw losowych, w którym rolę fałszerstwa pełni prawdziwy podpis innej osoby, zastosowano już w pracy, w której zaproponowano sieci syjamskie [2]. W pracy nie uwzględniono fałszerstw prostych, w których fałszerz zna jedynie imię i nazwisko osoby i podpisuje się po swojemu [1], ponieważ zbiór CEDAR ich nie zawiera.

Dla każdej osoby powstało więc 48 par pozytywnych i 48 par negatywnych (24 z fałszerstwami wykwalifikowanymi i 24 z fałszerstwami losowymi), dzięki czemu obie klasy są równoliczne i sieć nie faworyzuje żadnej z nich. Liczbę par w poszczególnych zbiorach przedstawiono w tabeli 3.3.

Tabela 3.3. Liczba par podpisów w zbiorach treningowym, walidacyjnym i testowym

Zbiór	Pozytywne	Wykwalifikowane	Losowe	Razem
treningowy	1680	840	840	3360
walidacyjny	480	240	240	960
testowy	480	240	240	960
razem	2640	1320	1320	5280

Pary zapisano w plikach CSV, w których dla każdej pary podano nazwy obu plików, numery osób, rodzaj pary oraz zbiór, do którego należy. Losowanie wykonano z ustalonymi ziarnami generatora liczb losowych, dzięki czemu pary można odtworzyć. Po zapisaniu pliki sprawdzono automatycznie: dla każdej pary porównano numer osoby odczytany z nazwy pliku z numerem zapisanym w pliku CSV, sprawdzono, czy oba podpisy należą do właściwego zbioru, oraz czy rodzaj pary jest zgodny z osobami, od których pochodzą podpisy. Sprawdzenie nie wykazało żadnych błędów.

4. Model sieci syjamskiej

5. Badania eksperymentalne i wyniki

6. Podsumowanie i wnioski końcowe

Literatura

- [1] Hafemann L.G., Sabourin R., Oliveira L.S.: Offline Handwritten Signature Verification — Literature Review. 7th International Conference on Image Processing Theory, Tools and Applications (IPTA), 2017.
- [2] Bromley J., Guyon I., LeCun Y., Säckinger E., Shah R.: Signature Verification using a „Siamese” Time Delay Neural Network. Advances in Neural Information Processing Systems 6 (NIPS 1993), str. 737–744.
- [3] Dey S., Dutta A., Toledo J.I., Ghosh S.K., Lladós J., Pal U.: SigNet: Convolutional Siamese Network for Writer Independent Offline Signature Verification. arXiv:1707.02131, 2017.
- [4] Kalera M.K., Srihari S.N., Xu A.: Offline Signature Verification and Identification Using Distance Statistics. International Journal of Pattern Recognition and Artificial Intelligence, vol. 18, nr 7, 2004, str. 1339–1360.
- [5] Hafemann L.G., Sabourin R., Oliveira L.S.: Learning Features for Offline Handwritten Signature Verification using Deep Convolutional Neural Networks. Pattern Recognition, vol. 70, 2017, str. 163–176.
- [6] CEDAR Signature Dataset, <https://www.kaggle.com/datasets/shreelakshmi gp/cedardataset>. Dostęp 29.09.2026.

STRESZCZENIE PRACY DYPLOMOWEJ INŻYNIERSKIEJ

**ZASTOSOWANIE ALGORYTMÓW SZTUCZNEJ INTELIGENCJI DO
ROZPOZNAWANIA AUTENTYCZNOŚCI PODPISU**

Autor: Maciej Pereślucha, nr albumu: EF-177139

Opiekun: dr inż. Paweł Górka

Słowa kluczowe: max. 5 słów kluczowych w 2 wierszach, oddzielanych przecinkami

Treść streszczenia po polsku

BSC THESIS ABSTRACT

**APPLICATION OF ARTIFICIAL INTELLIGENCE ALGORITHMS FOR
SIGNATURE AUTHENTICITY RECOGNITION**

Author: Maciej Pereślucha, Student's ID: EF-177139

Supervisor: Paweł Górka, PhD, Eng.

Key words: max. five keywords in English

Treść streszczenia po angielsku